

T.C.
KÜTAHYA DUMLUPINAR ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

POTANSİYEL TEHLİKELİ ASTEROİTLERİN MAKİNE ÖĞRENMESİ İLE SINIFLANDIRILMASI

DİLARA YILMAZ

BİTİRME PROJESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

DANIŞMAN
DR. ÖGR. ÜYESİ PINAR ÖZEN KAVAS

KÜTAHYA, 2026

İÇİNDEKİLER

İÇİNDEKİLER **1**
SİMGE VE KISALTMALAR **3**
ŞEKİL LİSTESİ **4**
ÖZET **5**
GİRİŞ **7**
1.1 Projenin Amaç ve Kapsamı 7
1.2 Proje Konusunun Anlam ve Önemi 8
LİTERATÜR TARAMASI **9**
2.1. Potansiyel Tehlikeli Asteroitler: Temel Kavramlar ve Sınıflandırma Kriterleri 9
2.2. Makine Öğrenmesi Tabanlı Asteroit Sınıflandırma Çalışmaları 9
2.3. Derin Öğrenme ve Grafik Sinir Ağları ile PHA Sınıflandırması 10
2.4. Kuantum Makine Öğrenmesi ile PHA Sınıflandırması 10
2.5. Açıklanabilir Yapay Zeka (XAI) ve SHAP Yöntemi 11
2.6. NEO Gözlem Sistemleri ve Veri Kaynakları 11
2.7. Mevcut Çalışmaların Karşılaştırması ve Literatürdeki Boşluklar 12
KULLANILAN TEKNOLOJİLER VE YÖNTEMLER **13**
3.1. Kullanılan Veri Seti ve Kaynağı 13
3.2. Geliştirme Ortamı ve Kullanılan Kütüphaneler 13
3.2.1. SpiceyPy ve SPICE Altyapısı 13
3.2.2. PyTorch ile Sinir Ağı Modeli 14
3.3. Keşifsel Veri Analizi (EDA) Yöntemi 14
3.4. Veri Ön İşleme Adımları 14
3.5. Kullanılan Makine Öğrenmesi Modelleri 15
3.6. Değerlendirme Metrikleri 15
3.7. SHAP ile Model Açıklanabilirliği 16
3.8. Çapraz Doğrulama (Cross-Validation) 16
UYGULAMA VE SONUÇLARI **17**
4.1. Keşifsel Veri Analizi Bulguları 17
4.2. Model Performans Sonuçları 21
4.2.1. Temel Konfigürasyon (est_diameter_min Hariç) 21
4.2.2.Genişletilmiş Özellik Konfigürasyonu (est_diameter_min Dahil) 21
4.3. Çapraz Doğrulama Sonuçları 23
4.4. ROC ve Precision-Recall Eğrileri 23
4.5. SHAP Özellik Önemi Analizi 24
4.5.1. SHAP Summary Plot (Beeswarm) 24
4.5.2. SHAP Bar Chart - Özellik Önemi Sıralaması 24
4.5.3. RF vs XGBoost SHAP Karşılaştırması 25
4.5.4. SHAP Dependence Plot 25

4.5.5. Temel Konfigürasyon SHAP Bulguları 26
4.5.6. Genişletilmiş Konfigürasyon SHAP Bulguları 26
4.6. Karar Eşiği Optimizasyonu 26
4.7. Model Karşılaştırmalı Radar Grafiği 27
4.8. Modeller Arası Karşılaştırmalı Değerlendirme 27
4.9. Sınıf Dengesizliği ve SMOTE Yöntemi 28
4.9.1. Sınıf Dengesizliği Problemi 28
4.9.2. SMOTE Algoritması 29
4.9.3. SMOTE Uygulaması ve Sonuçları 29
4.10. SPICE Altyapısı ile Apophis Yörünge Modellemesi 29
4.10.1. SPICE Sistemi ve NAIF Altyapısı 29
4.10.2. Kernel Kavramı 30
4.10.3. Referans Zaman ve Koordinat Sistemleri 30
4.10.4. Apophis (99942) Asteroidinin Modellenmesi 30
4.11. Sinir Ağı ve Ağaç Tabanlı Modeller Karşılaştırması 33
4.11.1. Yapay Sinir Ağı Mimarisi (AsteroidNet) 33
4.11.2. Kontrollü Deney Tasarımı 33
4.11.3. Karşılaştırma Sonuçları 34
4.12. Özellik Mühendisliği ve Model Etkisi 35
4.12.1. Türetilen Yeni Özellikler 36
4.12.2. FE'li ve FE'siz Model Karşılaştırması 36
4.13. Ana Model Seçimi - Random Forest 37
4.13.1. Model Seçiminin Gerekçesi 37
4.13.2. Ana Model Parametreleri 38
4.14. Web Simülasyonu: PHA Tespit Aracı 38
4.14.1. Simülasyonun Amacı 38
4.14.2. Sistem Mimarisi 38
SONUÇ **40**

SİMGE VE KISALTMALAR

AU: Astronomik Birim (Astronomical Unit)
EDA: Keşifsel Veri Analizi (Exploratory Data Analysis)
ET: Efemeris Zamanı (Ephemeris Time)
FE: Özellik Mühendisliği (Feature Engineering)
FN: Yanlış Negatif (False Negative)
FP: Yanlış Pozitif (False Positive)
JPL: Jet Propulsion Laboratory
KNN: K-En Yakın Komşu (K-Nearest Neighbors)
MOID: Minimum Yörünge Kesişim Mesafesi (Minimum Orbit Intersection Distance)
NAIF: Navigasyon ve Yardımcı Bilgi Tesisi (Navigation and Ancillary Information Facility)
NEO: Dünya'ya Yakın Cisimler (Near Earth Objects)
NN: Yapay Sinir Ağı (Neural Network)
PHA: Potansiyel Tehlikeli Asteroitler (Potentially Hazardous Asteroids)
PR-AUC: Hassasiyet-Duyarlılık Eğrisi Altındaki Alan (Precision-Recall Area Under Curve)
ROC-AUC: Alıcı İşletim Karakteristiği Eğrisi Altındaki Alan (Receiver Operating Characteristic - AUC)
SHAP: SHapley Additive exPlanations
SMOTE: Sentetik Azınlık Aşırı Örnekleme Tekniği (Synthetic Minority Over-sampling Technique)
SPICE: Uzay Aracı Gezegen Alet Koordinat Sistemi (Spacecraft Planet Instrument C-matrix Events)
SPK: Uzay Aracı ve Gezegen Çekirdeği (Spacecraft and Planet Kernel)
SVM: Destek Vektör Makineleri (Support Vector Machines)
TN: Doğru Negatif (True Negative)
TP: Doğru Pozitif (True Positive)
YSA: Yapay Sinir Ağı
XAI: Açıklanabilir Yapay Zeka (Explainable Artificial Intelligence)

ŞEKİL LİSTESİ

Şekil 1. Sınıf Dağılımı - Tehlikeli ve Tehlikesiz Asteroitlerin Sayısal ve Oransal Dağılımı (%90,3 / %9,7)
Şekil 2. Özellikler Arası Korelasyon Matrisi
Şekil 3. Özellik Dağılımları - Tehlikeli ve Tehlikesiz Asteroitlerin Karşılaştırmalı Histogramı
Şekil 4. Box Plot - Özellik Bazlı Aykırı Değer Analizi
Şekil 5. Mutlak Parlaklık ve Tahmini Çap Arasındaki Üstel (Ters Logaritmik) İlişki
Tablo 1. Model Karşılaştırma Sonuçları - Temel Konfigürasyon (est_diameter_min Hariç)
Tablo 2. Model Karşılaştırma Sonuçları - Genişletilmiş Konfigürasyon (est_diameter_min Dahil)
Şekil 6. Confusion Matrix - Tüm Modeller (est_diameter_min Dahil)
Tablo 3. Çapraz Doğrulama Sonuçları (5-Fold, Stratified)
Şekil 7. ROC Eğrisi ve Precision-Recall Eğrisi - Tüm Modeller
Şekil 8. SHAP Summary Plot - Random Forest (Beeswarm)
Şekil 9. SHAP Feature Importance - Random Forest (Bar Chart, main Branch)
Şekil 10. RF vs XGBoost - SHAP Özellik Önem Karşılaştırması
Şekil 11. SHAP Dependence Plot - est_diameter_min Özelliğinin PHA Tahminine Etkisi
Şekil 12. Model Karşılaştırmalı Radar Grafiği - Tüm Metrikler
Şekil 13. SMOTE Öncesi ve Sonrası Sınıf Dağılımı Karşılaştırması
Şekil 14. Apophis (99942) – Dünya'ya Mesafe Grafiği (2025–2035)
Şekil 15. İç Güneş Sistemi – Ekliptik Düzlem Görünümü (Dünya, Mars, Apophis)
Şekil 16. Apophis (99942) – İnteraktif 3D Yörünge Görselleştirmesi
Şekil 17. Neural Network Eğitim Eğrileri – 4 Konfigürasyon
Şekil 18. NN vs RF vs XGBoost – Confusion Matrix Karşılaştırması
Şekil 19. NN vs RF vs XGBoost – ROC ve PR Eğrileri
Şekil 20. Tüm Modeller – Radar Karşılaştırması (Notebook 05)
Tablo 4. SMOTE Öncesi/Sonrası Sınıf Dağılımı
Tablo 5. Örnek Kernel'ler
Tablo 6. Yapay Sinir Ağları Mimarisi
Tablo 7. Dört Konfigürasyon Tasarımı
Tablo 8. NN vs RF vs XGBoost Karşılaştırma Tablosu (FE ile)
Tablo 9. Feature Engineering ile Türetilmiş Özellikler
Tablo 10. NN vs RF vs XGBoost Karşılaştırma Tablosu (FE ile)
Tablo 11. Tüm Modeller F1 Sıralaması (Notebook 05)

ÖZET

POTANSİYEL TEHLİKELİ ASTEROİTLERİN MAKİNE ÖĞRENMESİ İLE SINIFLANDIRILMASI

Dilara Yılmaz

Bilgisayar Mühendisliği Bölümü

Bitirme Projesi

Proje Danışmanı: Dr. Öğr. Üyesi Pınar Özen Kavas

Dünya'ya yakın cisimler (Near Earth Objects - NEO) arasında yer alan Potansiyel Tehlikeli asteroitler (Potentially Hazardous Asteroids - PHA), olası çarpışma riski nedeniyle gezegen savunması açısından kritik öneme sahip gök cisimleridir. Bu çalışmada, NASA Jet Propulsion Laboratory tarafından derlenen ve 90.000'i aşkın kayıt içeren NEO veri seti üzerinde makine öğrenmesi ve derin öğrenme yöntemleri kullanılarak PHA sınıflandırması gerçekleştirilmektedir.

Çalışma kapsamında öncelikle veri ön işleme ve keşifsel veri analizi aşamalarında eksik değer yönetimi, aykırı değer tespiti ve veri setindeki belirgin sınıf dengesizliğinin giderilmesi amacıyla SMOTE tekniği uygulanmaktadır. Orbital parametrelerden yeni fiziksel özellikler türetilerek özellik mühendisliği gerçekleştirilmekte; elde edilen zenginleştirilmiş veri seti üzerinde Random Forest, XGBoost, Lojistik Regresyon ve Destek Vektör Makineleri algoritmaları eğitilip karşılaştırmalı olarak değerlendirilmektedir. Bu klasik makine öğrenmesi yaklaşımlarına ek olarak, tam bağlantılı katmanlardan oluşan özgün bir derin öğrenme modeli tasarlanmakta ve söz konusu algoritmalarla başarım karşılaştırması yapılmaktadır. Model değerlendirmesinde doğruluk, kesinlik, duyarlılık, F1-skoru ve ROC-AUC metrikleri esas alınmaktadır. Yüksek riskli sınıflandırma görevlerinde salt tahmin doğruluğunun ötesine geçme gerekliliğinden hareketle, SHAP (SHapley Additive exPlanations) yöntemi aracılığıyla modellerin karar mekanizmaları yorumlanmakta ve hangi yörüngesel parametrelerin PHA tespitinde belirleyici rol oynadığı görsel olarak ortaya konulmaktadır. Bunun yanı sıra, NASA/NAIF'in SPICE altyapısının Python arayüzü olan SpiceyPy kütüphanesi kullanılarak 99942 Apophis başta olmak üzere seçili asteroitlerin 2025–2035 yılları arasındaki yörünge dinamikleri hesaplanmakta ve Plotly ile etkileşimli üç boyutlu animasyonlar oluşturulmaktadır.

Geliştirilen sinir ağı modelinin (AsteroidNet) ağaç tabanlı modeller karşısındaki performansı Shwartz-Ziv ve Armon (2022)'un tablo verilerinde ağaç tabanlı modellerin yapay sinir ağlarını geçtiğine ilişkin bulgusuyla örtüşmektedir. Tüm karşılaştırmalar sonucunda en tutarlı performansı sergileyen Random Forest modeli ana model olarak seçilmiş; bu model

NASA NeoWs API'si ve Kepler yörünge mekaniği ile entegre edilerek gerçek zamanlı PHA tespit simülasyonu oluşturulmuştur.

Çalışmanın bulguları; makine öğrenmesi ve derin öğrenme modellerinin PHA sınıflandırmasındaki göreli üstünlüklerini, kritik yörüngesel özelliklerin model kararları üzerindeki etkisini ve SPICE tabanlı simülasyonun sınıflandırma çıktılarını fiziksel bir bağlama oturtmadaki katkısını ortaya koymaktadır. Bu yaklaşımın, otomatik asteroit tehdit değerlendirme sistemlerine yönelik gelecekteki çalışmalara metodolojik ve teknik açıdan katkı sağlayacağı öngörülmektedir.

Anahtar Kelimeler: Potansiyel Tehlikeli asteroitler, makine öğrenmesi, derin öğrenme, SHAP, SpiceyPy, yörünge simülasyonu, sınıf dengesizliği, NEO sınıflandırması

BÖLÜM 1

GİRİŞ

1.1 Projenin Amaç ve Kapsamı

Bu çalışmanın temel amacı, NASA'nın Jet Propulsion Laboratory (JPL) tarafından derlenen Near Earth Object (NEO) veri seti üzerinde makine öğrenmesi ve derin öğrenme yöntemlerini bir arada kullanarak Potansiyel Tehlikeli asteroitlerin (Potentially Hazardous Asteroids - PHA) yüksek doğrulukla sınıflandırılmasıdır. Bu doğrultuda proje; veri ön işleme, model geliştirme, model yorumlanabilirliği, simülasyon ve görselleştirme olmak üzere birbiriyle entegre birkaç temel bileşenden oluşmaktadır.

Projenin kapsamı aşağıdaki çalışma alanlarını kapsamaktadır:

Veri Ön İşleme ve Keşifsel Veri Analizi: 90.000'i aşkın kaydı barındıran **neo_v2.csv** veri seti üzerinde eksik değer analizi, aykırı değer tespiti, özellik ölçeklendirme ve hedef değişken kodlaması gerçekleştirilmektedir. Veri setindeki belirgin sınıf dengesizliği (PHA oranı yaklaşık %10–15) SMOTE (Synthetic Minority Over-sampling Technique) ve sınıf ağırlıklandırma stratejileriyle ele alınmaktadır.

Makine Öğrenmesi Modelleri: Lojistik Regresyon, Rastgele Orman (Random Forest), XGBoost ve Destek Vektör Makineleri (SVM) gibi denetimli öğrenme algoritmaları eğitilmekte ve karşılaştırmalı biçimde değerlendirilmektedir. Model başarımı; doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1-skoru ve ROC-AUC metrikleriyle ölçülmektedir.

Derin Öğrenme Modeli: Tam bağlantılı (fully connected) bir sinir ağı mimarisi PyTorch veya TensorFlow/Keras çerçevesinde tasarlanmakta ve eğitilmektedir. Bu modelin sınıflandırma başarımı, klasik makine öğrenmesi algoritmaları ile sistematik biçimde karşılaştırılmaktadır.

Özellik Mühendisliği (Feature Engineering): Mevcut orbital parametrelerden türetilen yeni fiziksel özellikler (tahmini asteroit çapı, yörünge periyodu, normalize edilmiş MOID, Tisserand parametresi vb.) modele dahil edilerek başarım artışı araştırılmaktadır.

Model Yorumlanabilirliği: SHAP (SHapley Additive exPlanations) yöntemiyle eğitilmiş modellerin karar mekanizmaları şeffaflaştırılmakta, hangi yörüngesel ve fiziksel parametrelerin PHA sınıflandırmasında belirleyici rol oynadığı görsel olarak ortaya konulmaktadır.

SPICE Tabanlı Yörünge Simülasyonu ve Görselleştirme: NASA/NAIF'in SPICE altyapısının Python arayüzü olan SpiceyPy kütüphanesi aracılığıyla, özellikle 99942 Apophis olmak üzere seçili asteroitlerin 2025–2035 yılları arasındaki yörünge pozisyonları hesaplanmakta ve Plotly ile etkileşimli üç boyutlu animasyonlar oluşturulmaktadır.

1.2 Proje Konusunun Anlam ve Önemi

Dünya'ya yakın cisimler (Near Earth Objects - NEO), güneş sisteminin oluşum sürecinden bu yana varlığını sürdüren ve insanlık için gerçek bir çarpışma riski taşıyan gök cisimlerini kapsamaktadır. Tarihsel kanıtlar, büyük asteroit çarpışmalarının biyolojik kitlesel yok oluş olaylarına yol açabildiğini göstermektedir; nitekim Kretase-Paleogen sınırında yaşanan çarpışma, Dünya'daki türlerin büyük çoğunluğunun yok olmasıyla sonuçlanmıştır. Bu bağlamda, Potansiyel Tehlikeli asteroitlerin zamanında ve güvenilir biçimde tespit edilmesi, yalnızca akademik bir ilgi alanı olmaktan öte, insanlığın uzun vadeli güvenliği açısından stratejik bir öneme sahiptir.

NASA, ESA ve diğer uzay ajansları bu tehdide karşı DART (Double asteroid Redirection Test) gibi erken müdahale misyonları geliştirmekte; ancak bu tür misyonların başarısı, tehdit oluşturabilecek cisimlerin yeterince erken tanımlanmasına doğrudan bağlıdır. Mevcut tespit yöntemleri büyük ölçüde gözlemsel verilere dayanmakta, dolayısıyla geniş ölçekli veri setlerini hızla işleyebilecek ve yüksek hassasiyetle sınıflandırma yapabilecek otomatik sistemlere olan ihtiyaç giderek artmaktadır.

Bu çalışma, söz konusu ihtiyaca makine öğrenmesi ve derin öğrenme perspektifinden yanıt vermeyi amaçlamaktadır. Klasik sınıflandırma algoritmalarının karşılaştırmalı analizi ve derin öğrenme modeliyle entegrasyonu, hangi yaklaşımın PHA tespitinde daha güvenilir sonuçlar ürettiğini ortaya koyacaktır. Öte yandan SHAP analizi, yalnızca tahmin doğruluğunu artırmakla kalmayıp modelin karar mekanizmasını uzmanların yorumlayabileceği biçimde şeffaflaştırmakta; böylece kör bir kara kutu sisteminin ötesine geçilmektedir. Bu özellik, gerçek dünya uygulamalarında güvenilir karar destek sistemleri geliştirmek açısından büyük önem taşımaktadır.

SPICE tabanlı yörünge simülasyonu bileşeni ise projeye özgün bir boyut katmaktadır. NASA'nın profesyonel gezegen bilimi altyapısını doğrudan kullanan bu bileşen, makine öğrenmesiyle tespit edilen yüksek riskli asteroitlerin gerçek yörünge dinamikleri çerçevesinde görselleştirilmesine olanak tanımakta ve sınıflandırma çıktılarını yalnızca istatistiksel olmaktan çıkarıp fiziksel gerçekliğe dayandırmaktadır. Özellikle 2029 yakın geçişiyle kamuoyunun gündemine giren 99942 Apophis üzerine gerçekleştirilecek on yıllık yörünge analizi, projenin bilimsel inandırıcılığını pekiştirmektedir.

Son olarak, sınıf dengesizliği problemi bu alanda özgün bir zorluk oluşturmaktadır: PHA olarak sınıflandırılan asteroitler veri setinin yalnızca küçük bir bölümünü oluşturmakta ve bu durum modelin tehlikeli cisimleri gözden kaçırma eğilimi taşımasına yol açmaktadır. Tehlikeli bir asteroidi tehlikesiz olarak sınıflandırmanın asimetrik maliyeti göz önünde bulundurulduğunda, SMOTE ve duyarlılık odaklı metrik optimizasyonu gibi tekniklerin uygulanması yalnızca teknik bir tercih değil, etik bir zorunluluk olarak değerlendirilmelidir.

Tüm bu bileşenleriyle bu çalışma; makine öğrenmesi, derin öğrenme, model yorumlanabilirliği ve uzay bilimi araçlarını bir arada kullanan, gerçek bir NASA veri seti üzerinde yürütülen bütünleşik ve çok katmanlı bir mühendislik projesi niteliği taşımaktadır.

BÖLÜM 2

LİTERATÜR TARAMASI

2.1. Potansiyel Tehlikeli Asteroitler: Temel Kavramlar ve Sınıflandırma Kriterleri

Güneş Sistemi'ndeki asteroitler, özellikle Dünya'nın yörüngesini kesen ya da yakın geçiş yapan cisimler, uzay biliminin en kritik araştırma konularından birini oluşturmaktadır. NASA'nın Yakın Dünya Nesneleri (Near-Earth Objects, NEO) sınıflandırmasına göre, yörünge yarı büyük ekseni 1,0 AU'dan büyük ve yörünge perihelion mesafesi 1,017 AU'dan küçük olan cisimler Apollo grubu olarak; yarı büyük ekseni 1,0 AU'dan küçük olanlar ise Aten grubu olarak tanımlanmaktadır **[1]**. Potansiyel Tehlikeli Asteroit (Potentially Hazardous Asteroid, PHA) kavramı ise ilk kez 1995 yılında İngiliz gökbilimci Brian Marsden tarafından BM konferansında gündeme getirilmiştir **[2]**.

Bir asteroidin PHA olarak sınıflandırılabilmesi için iki temel kriter bulunmaktadır: Dünya ile arasındaki Minimum Yörünge Kesişim Mesafesi'nin (Minimum Orbit Intersection Distance, MOID) 0,05 AU veya daha az olması ve mutlak parlaklığının (H) 22,0 veya daha parlak olması **[1, 2]**. Bu ikinci kriter, yaklaşık 140 metre ve üzeri çapa karşılık gelmekte olup bu boyuttaki cisimlerin Dünya atmosferine girmeden önce tamamen parçalanmayacağını ve bölgesel ya da daha geniş çaplı hasar verebileceğini ifade etmektedir. Bununla birlikte, 2013 yılında Rusya'nın Chelyabinsk şehrinde yaşanan olay, yalnızca 20 metre çapındaki bir meteoritın dahi 1.500'den fazla kişinin yaralanmasına ve altı şehirde binaların hasar görmesine neden olabileceğini ortaya koymuştur **[3]**. Tunguska olayında ise yaklaşık 50 metre çapındaki bir cisim, 2.000 km²'den fazla Sibirya ormanını tahrip etmiştir **[4]**.

Li ve diğerleri (2019), ortalama hareket rezonanslarını (mean motion resonances) kullanarak PHA riskini değerlendiren sayısal bir teknik sunmuş ve keşfedilen PHA'ların yaklaşık %9,3'ünün Dünya ile rezonans içinde olduğunu belirlemiştir **[5]**. Bu çalışma, rezonans dinamiğinin gezegen savunma misyonları açısından kritik bir referans niteliği taşıdığını vurgulamaktadır.

2.2. Makine Öğrenmesi Tabanlı Asteroit Sınıflandırma Çalışmaları

PHA sınıflandırmasında makine öğrenmesi yöntemlerinin kullanımı son yıllarda hız kazanmıştır. Delina ve diğerleri (2024), KNN (K-En Yakın Komşu), Naive Bayes ve Rastgele Orman (Random Forest) algoritmalarını yörüngesel parametreler üzerinde test etmiş; Rastgele Orman'ın %99,53 doğruluk oranıyla en iyi performansı sergilediğini, ardından Naive Bayes (%92,00) ve KNN (%84,45) algoritmasının geldiğini raporlamıştır **[6]**. Çalışma aynı zamanda bu sınıflandırıcıların erken uyarı sistemlerine entegrasyonunun gezegen savunması açısından önemini de vurgulamaktadır.

Buana ve diğerleri ise beş makine öğrenmesi algoritması ve beş derin öğrenme modelinden oluşan toplam on yöntemi, hem Kaggle'dan elde edilen hem de NASA'nın NeoWS RESTful web servisinden derlenen iki farklı veri kümesi üzerinde değerlendirmiştir **[7]**. Bu kapsamlı karşılaştırma, veri kümesinin niteliğine bağlı olarak model performansının belirgin biçimde değişebildiğini ortaya koymaktadır. Chaitanya Prasad ve diğerleri (2020) ise Pan-STARRS teleskobundan elde edilen gerçek zamanlı FITS dosya verileri üzerinde makine öğrenmesini uygulayarak Astrometrica yazılımının yerine geçebilecek %60'ın üzerinde verimlilik sağlayan bir sistem önermiştir **[8]**.

Ciacci ve diğerleri (2023), asteroitlerin ortak yörünge hareketlerini sınıflandırmak amacıyla tsfresh paketi ile zaman serisi özellik çıkarımına dayanan bir veri analizi hattı oluşturmuştur. Gerçek, ideal ve pertürbe edilmiş olmak üzere üç farklı veri kümesi kullanan bu çalışma, SHapley Additive exPlanations (SHAP) yöntemiyle açıklanabilirlik analizini de entegre etmiştir **[9]**. Elde edilen sonuçlar, model yorumlanabilirliğinin yalnızca doğruluk metriklerinin ötesinde bilimsel değer taşıdığını açıkça ortaya koymaktadır.

2.3. Derin Öğrenme ve Grafik Sinir Ağları ile PHA Sınıflandırması

Klasik makine öğrenmesi yöntemlerinin yanı sıra derin öğrenme tabanlı yaklaşımlar da PHA sınıflandırmasında giderek daha fazla yer bulmaktadır. Jean Jacques (2025), asteroitleri graf düğümleri olarak modelleyen ve aralarındaki dinamik ilişkileri kenar ağırlıklarıyla temsil eden bir Graf Sinir Ağı (Graph Neural Network, GNN) mimarisi sunmuştur. 958.524 kayıtlık NASA veri kümesi üzerinde yürütülen bu çalışmada, yalnızca %0,22 oranında tehlikeli label içeren aşırı sınıf dengesizliğine rağmen SMOTE tekniğiyle %99 genel doğruluk ve 0,99 AUC değeri elde edilmiştir **[4]**. Özellik önemi analizi, albedo, perihelion mesafesi ve yarı büyük eksenin temel belirleyiciler olduğunu göstermiştir.

Söz konusu çalışma aynı zamanda NASA'nın NEO Surveyor ve ESA'nın Ramses gibi gelecek misyonlar için yorumlanabilir ve ölçeklenebilir bir çözüm sunması bakımından da önem taşımaktadır. Bu bulgular, derin öğrenme yöntemlerinin yalnızca yüksek doğruluk sağlamakla kalmayıp asteroitler arasındaki karmaşık dinamik ilişkileri de ortaya çıkarmadaki potansiyelini açıkça ortaya koymaktadır.

2.4. Kuantum Makine Öğrenmesi ile PHA Sınıflandırması

Asteroit sınıflandırmasında geleneksel makine öğrenmesi yöntemlerinin performans sınırlarına ulaşılmasıyla birlikte kuantum hesaplama tabanlı yaklaşımlar gündeme gelmiştir. Bhavsar ve diğerleri (2023), PHA sınıflandırması için Değişken Kuantum Devreler (Variational Quantum Circuits, VQC) ve PegasosQSVC algoritmalarını kullanan denetimli bir Kuantum Makine Öğrenmesi (Quantum Machine Learning, QML) modeli önermiştir. Çalışmada klasik sınıflandırma algoritmalarıyla yapılan karşılaştırmada önerilen QML tabanlı yaklaşımın %98,11 doğruluk ve ortalama %92,69 F1-skoru ile diğer yöntemlerin önüne geçtiği raporlanmıştır **[10]**.

Bu sonuçlar, kuantum hesaplama paradigmasının asteroit verilerindeki non-lineer ve yüksek boyutlu örüntüleri daha etkin biçimde yakalayabildiğine işaret etmektedir. Bununla birlikte kuantum donanımına erişimin sınırlılığı ve kuantum gürültüsünün pratik uygulamalardaki etkileri, bu alandaki araştırmaların henüz olgunlaşma sürecinde olduğunu göstermektedir.

2.5. Açıklanabilir Yapay Zeka (XAI) ve SHAP Yöntemi

Makine öğrenmesi modellerinin karar mekanizmalarının şeffaf hale getirilmesi, özellikle bilimsel uygulamalarda büyük önem taşımaktadır. Bu bağlamda SHAP (SHapley Additive exPlanations), karmaşık modellerin tahminlerini yorumlamak için oyun teorisi prensiplerinden yararlanan birleşik bir çerçeve sunmaktadır. Lundberg ve Lee (2017), SHAP'ın altı farklı mevcut yöntemi tek bir teorik çatı altında nasıl birleştirdiğini göstermiş; her özelliğe belirli bir tahmin için önem değeri atanmasını sağlayan katkısal özellik atıf ölçüleri sınıfı tanımlamıştır **[11]**. Bu özellik, SHAP'ı yalnızca doğruluk değil, yorumlanabilirlik de gerektiren asteroit sınıflandırma gibi alanlarda vazgeçilmez bir araç haline getirmektedir.

Ciacci ve diğerleri (2023) ve Jean Jacques (2025) gibi çalışmalar, SHAP'ın asteroit verilerine uygulanmasının model açıklanabilirliğine nasıl katkı sağladığını somut biçimde ortaya koymuştur. SHAP analizi sayesinde hangi yörüngesel parametrelerin (MOID, yarı büyük eksen, eğim açısı vb.) sınıflandırma kararları üzerinde belirleyici olduğu tespit edilebilmekte; bu durum hem bilimsel yorumlama hem de model doğrulama açısından kritik bir değer sunmaktadır **[9, 11]**.

2.6. NEO Gözlem Sistemleri ve Veri Kaynakları

PHA sınıflandırması için kullanılan makine öğrenmesi modellerinin başarısı büyük ölçüde veri kalitesine ve gözlem altyapısına bağlıdır. Szabó ve diğerleri (2025), Macaristan'daki Konkoly Gözlemevi'nin Piszkéstető Dağı İstasyonu'nda gerçekleştirilen NEO ve anlık çarpan keşiflerini ele almıştır. Çalışma, 2022 EB5, 2023 CX1 ve 2024 BX1'in anlık çarpan keşiflerini ayrıntılı biçimde açıklamakta; sürekli geliştirilen Schmidt teleskobu ve güçlü analiz-gözlem geri bildirimi sayesinde metre boyutundaki cisimlere duyarlılığın nasıl artırıldığını ortaya koymaktadır **[12]**.

NASA'nın JPL/CNEOS veri tabanı ise 1 milyona yaklaşan asteroit kaydıyla PHA sınıflandırma araştırmalarının temel veri altyapısını oluşturmaktadır. Bu veri tabanında her asteroit için MOID, mutlak parlaklık (H), yarı büyük eksen (a), eksantrisite (e), yörünge eğim açısı (i) ve albedo gibi yörüngesel ve fiziksel parametreler yer almaktadır. Mevcut tezde de bu veri kaynağından yararlanılacak olup elde edilen parametreler üzerinde makine öğrenmesi modelleri uygulanacaktır.

2.7. Mevcut Çalışmaların Karşılaştırması ve Literatürdeki Boşluklar

İncelenen çalışmalar değerlendirildiğinde, PHA sınıflandırmasında en yaygın kullanılan algoritmaların Rastgele Orman, Destek Vektör Makineleri ve yapay sinir ağları olduğu görülmektedir. Bununla birlikte bazı önemli eksiklikler de dikkat çekmektedir. Birincisi, pek çok çalışma yalnızca doğruluk metriklerini ön plana çıkarmakta, model yorumlanabilirliğini ve özellik önemine ilişkin analizleri ihmal etmektedir. İkincisi, veri dengesizliği sorunu (PHA oranının tüm asteroitler içinde çok düşük kalması) yöntemsel açıdan yeterince ele alınmamaktadır. Üçüncüsü, SHAP gibi açıklanabilirlik araçlarının asteroit sınıflandırmasına sistematik biçimde entegre edildiği kapsamlı çalışma sayısı oldukça sınırlıdır.

Bu tez, söz konusu eksiklikleri gidermek amacıyla XGBoost ve Rastgele Orman modellerini SHAP tabanlı açıklanabilirlik analiziyle birleştiren bütünleşik bir yaklaşım sunmayı hedeflemektedir. Ayrıca NASA JPL veri tabanından derlenen geniş kapsamlı bir veri kümesi üzerinde kapsamlı bir keşifsel veri analizi (EDA) gerçekleştirilecek ve SpiceyPy kütüphanesi ile yörüngesel görselleştirmeler oluşturulacaktır. Bu çok katmanlı yaklaşımın, asteroit sınıflandırma araştırmalarına hem doğruluk hem de yorumlanabilirlik boyutunda anlamlı katkılar sağlayacağı öngörülmektedir.

BÖLÜM 3

KULLANILAN TEKNOLOJİLER VE YÖNTEMLER

3.1. Kullanılan Veri Seti ve Kaynağı

Bu çalışmada NASA JPL (Jet Propulsion Laboratory) tarafından yönetilen Small-Body Database'den derlenen asteroit verisi kullanılmıştır. Veri seti, Kaggle platformu üzerinden erişilebilen "NASA Nearest Earth Objects" başlıklı veri kümesidir ve 90.000'i aşan asteroit kaydı ile 40'tan fazla özellik içermektedir. Veri seti, her asteroidin gözlemsel ve yörüngesel parametrelerini kapsamakta olup hedef değişken olarak hazardous (tehlikeli/tehlikesiz) ikili etiketi barındırmaktadır.

Veri setinde yer alan temel özellikler şu Şekilde özetlenebilir: tahmini minimum çap (est_diameter_min), tahmini maksimum çap (est_diameter_max), göreli hız (relative_velocity), kaçış mesafesi (miss_distance), mutlak parlaklık (absolute_magnitude) ve tehlikelilik etiketi (hazardous). Kullanılan veri setinde MOID (Minimum Orbit Intersection Distance) değeri doğrudan yer almamakla birlikte, hedef değişken NASA JPL tarafından MOID $\leq$ 0,05 AU ve H $\leq$ 22 kriterleri gözetilerek atandığından bu bilgi hedef etikete dolaylı olarak yansımaktadır. Analizlerde MOID'e en yakın gösterge olarak miss_distance özelliği kullanılmıştır.

3.2. Geliştirme Ortamı ve Kullanılan Kütüphaneler

Proje, Google Colab platformu üzerinde Python programlama dili kullanılarak geliştirilmiştir. Google Colab, GPU desteği, paylaşım kolaylığı ve Google Drive entegrasyonu nedeniyle akademik makine öğrenmesi çalışmaları için tercih edilen bir ortamdır. Tüm ara çıktılar ve eğitilmiş modeller Google Drive'da /content/drive/MyDrive/nasa_asteroid/ dizininde saklanmış; notebook'lar arası veri aktarımı bu yol üzerinden gerçekleştirilmiştir.

Kullanılan başlıca Python kütüphaneleri şunlardır: pandas ve numpy veri işleme ve sayısal hesaplamalar için; matplotlib, seaborn ve plotly görselleştirme için; scikit-learn sınıflandırma modelleri, ön işleme ve değerlendirme için; xgboost XGBoost modelinin uygulanması için; shap model açıklanabilirlik analizleri için; imbalanced-learn SMOTE ve dengesizlik çözüm teknikleri için; spiceypy ve astropy ise NASA SPICE tabanlı yörünge hesaplama ve görselleştirme için kullanılmıştır.

3.2.1. SpiceyPy ve SPICE Altyapısı

NASA/NAIF'in SPICE (Spacecraft Planet Instrument C-matrix Events) altyapısının Python arayüzü olan SpiceyPy (versiyon 8.1.0) kütüphanesi, 99942 Apophis asteroidinin yörünge hesaplamaları için kullanılmıştır. SPICE, gök cisimlerinin konum ve hız bilgilerini içeren SPK (Spacecraft and Planet Kernel) dosyaları, zaman dönüşüm tabloları içeren LSK

(Leapseconds Kernel) ve gezegen fiziksel sabitlerini barındıran PCK (Planetary Constants Kernel) olmak üzere üç tür kernel dosyasıyla çalışmaktadır. Apophis'e ait SPK kernel'ı JPL Horizons API'si üzerinden otomatik olarak indirilmiştir.

3.2.2. PyTorch ile Sinir Ağı Modeli

Tam bağlantılı (fully connected) yapay sinir ağı modeli PyTorch çerçevesiyle geliştirilmiştir. Model, dört gizli katmandan (256→128→64→32 nöron) oluşmakta; her katmanda Batch Normalization ve Dropout düzenleme teknikleri uygulanmaktadır. Sınıf dengesizliğine karşı Focal Loss (α=0.75, γ=2.0) kayıp fonksiyonu tercih edilmiştir.

3.3. Keşifsel Veri Analizi (EDA) Yöntemi

Keşifsel veri analizi (Exploratory Data Analysis, EDA) aşamasında veri setinin yapısı, dağılımı ve içerdiği örüntüler sistematik biçimde incelenmiştir. Bu aşamada öncelikle df.info(), df.describe() ve df.isnull().sum() fonksiyonları kullanılarak veri tipi uyumluluğu, istatistiksel özellikler ve eksik değerlerin dağılımı değerlendirilmiştir. Veri setinde eksik değer bulunmadığı doğrulanmıştır.

Sınıf dengesizliği analizi, tehlikeli asteroit oranının hesaplanarak bir eşik değeriyle karşılaştırılması ve sonucun koşullu bir karar yapısına bağlanması yoluyla otomatikleştirilmiştir. Hedef değişkenin ikili dağılımı çubuk grafik ve pasta grafik ile görselleştirilmiştir. Korelasyon analizi için sayısal sütunları kapsayan üçgen maskeli ısı haritası (heatmap) kullanılmış; özellikler arası doğrusal ilişkiler +1 ile −1 arasındaki renk skalasıyla görselleştirilmiştir.

Her özelliğin sınıfa göre (PHA / PHA olmayan) dağılımı yoğunluk histogramları ve box plot grafikleriyle incelenmiştir. Histogram analizi, absolute_magnitude özelliğinin iki sınıf arasında en belirgin ayrımı sağladığını ortaya koymuştur: tehlikeli asteroitler 15–22 büyüklük aralığında yoğunlaşırken, tehlikesiz olanlar 22–30 aralığına dağılmaktadır. miss_distance özelliğinin düz dağılımı ise PHA tanımının yalnızca mesafeye değil, boyut kriterine de dayandığını yansıtmaktadır. Box plot analizinde miss_distance ve absolute_magnitude için iki sınıf arasında belirgin medyan farklılıkları gözlemlenmiştir.

3.4. Veri Ön İşleme Adımları

Veri ön işleme süreci aşağıdaki sırayla uygulanmıştır:

Gereksiz sütunların çıkarılması: id, name, est_diameter_max, neo_reference_id, orbiting_body ve sentry_object sütunları modelin eğitimiyle doğrudan ilişkili olmadığından kaldırılmıştır. est_diameter_max sütununun çıkarılması, est_diameter_min ile arasındaki çok yüksek korelasyonun çok eş doğrusallık (multicollinearity) sorununa yol açmasını önlemek amacıyla tercih edilmiştir.

Eğitim/test bölünmesi: Veri seti %80 eğitim, %20 test olacak Şekilde bölünmüştür. stratify=y parametresi kullanılarak sınıf oranlarının (%90 tehlikesiz / %10 tehlikeli) her iki kümede de korunması sağlanmıştır. Tekrar üretilebilirlik için random_state=42 sabit değeri kullanılmıştır.

Eksik değer impütasyonu: Eksik değerlerin medyan ile doldurulması için scikit-learn'ün SimpleImputer sınıfı kullanılmıştır. Veri sızıntısını (data leakage) önlemek amacıyla fit_transform yalnızca eğitim setine uygulanmış; test setine yalnızca transform işlemi yapılmıştır.

Aykırı değer tespiti: IQR (Interquartile Range) yöntemi tercih edilmiştir. Çap değişkenlerindeki aşırı büyük gözlemler ortalama ve standart sapmayı çarpıtacağından, medyan tabanlı IQR bu tür sağa çarpık dağılımlarda Z-score yöntemine kıyasla daha güvenilir sonuçlar üretmektedir. Orbital parametreler fiziksel sınırlara sahip olduğundan, tespit edilen aykırı değerler silinmeksizin raporlanmıştır.

Özellik ölçeklendirme (Feature Scaling): StandardScaler ile Z-skoru normalleştirmesi uygulanmıştır. Bu işlem de yalnızca eğitim setine fit edilerek veri sızıntısı önlenmiştir. Ölçeklendirilmemiş ham eğitim verisi, çapraz doğrulama (cross-validation) deneyleri için X_train_raw adıyla ayrıca saklanmıştır.

3.5. Kullanılan Makine Öğrenmesi Modelleri

Bu çalışmada beş farklı sınıflandırıcı algortiması eğitilmiş ve karşılaştırılmıştır:

Lojistik Regresyon (Logistic Regression): Sigmoid fonksiyonuna dayanan, doğrusal karar sınırı oluşturan temel (baseline) modeldir. Sonuçların yorumlanabilirliği yüksektir. Sınıf dengesizliğiyle başa çıkmak için class_weight='balanced' parametresi kullanılmıştır.

Rastgele Orman (Random Forest): 200 karar ağacından oluşan bir topluluk (ensemble) modelidir. class_weight='balanced_subsample' parametresi ile her bootstrap örneklemi için bağımsız ağırlık ataması yapılmış; min_samples_leaf=5 ile aşırı öğrenme hafifçe kısıtlanmıştır.

XGBoost: Gradient boosting temelli, genellikle yüksek tablo veri performansı sergileyen bir algoritmadır. Sınıf dengesizliğini ele almak amacıyla negatif/pozitif örnek oranına göre hesaplanan scale_pos_weight parametresi kullanılmıştır. 300 ağaç, max_depth=6, learning_rate=0,1 ile yapılandırılmıştır.

Destek Vektör Makinesi (SVM, RBF Çekirdeği): Yüksek boyutlu uzayda optimal hiper düzlem arayan bir modeldir. class_weight='balanced' ve probability=True parametreleriyle yapılandırılmış; olasılık tahmini için Platt ölçeklemesi uygulanmıştır.

K-En Yakın Komşu (KNN, k=11): Komşuluk tabanlı, örnek belleğe dayanan bir sınıflandırıcıdır. KNN'de class_weight parametresi yapısal olarak desteklenmediğinden, sınıf dengesizliğini kısmen telafi etmek amacıyla weights='distance' parametresi kullanılmıştır; ancak bu parametrenin etki alanı komşuların uzaklık ağırlıklandırmasıyla sınırlıdır.

3.6. Değerlendirme Metrikleri

Sınıf dengesizliğinin söz konusu olduğu bu veri setinde yalnızca doğruluk (accuracy) metriki yanıltıcı sonuçlar üretmektedir. Tüm tahminleri "tehlikesiz" olarak veren bir model dahi

yaklaşık %90 doğruluk oranı elde edebilmektedir. Bu nedenle model değerlendirmesinde birden fazla metrik eş zamanlı olarak kullanılmıştır:

Recall (Duyarlılık): TP / (TP + FN) formülüyle hesaplanan bu metrik, gerçek tehlikeli asteroitlerin ne kadarının tespit edildiğini gösterir. Tehlikeli bir asteroidi kaçırmanın (FN) tehlikesiz birini yanlış sınıflandırmaktan çok daha ağır sonuçları olduğu bu senaryo için en kritik metriktir.

F1-Score: Precision ile Recall'un harmonik ortalamasıdır. Hem yanlış pozitif hem de yanlış negatifleri eş zamanlı cezalandırır. Sınıf dengesizliğinde Accuracy'ye kıyasla çok daha güvenilir bir denge ölçütüdür.

ROC-AUC: Karar eşiği değiştikçe TPR (Recall) ile FPR arasındaki ilişkiyi özetler; eşik bağımsız genel ayrım gücünü ölçer.

PR-AUC (Precision-Recall AUC): Pozitif sınıfın çok nadir olduğu dengesiz veri setlerinde ROC-AUC'tan daha bilgilendirici bir metriktir.

Ayrıca confusion matrix görselleştirmesi, her model için TP, TN, FP ve FN değerlerini hem sayı hem yüzde olarak sunmakta; özellikle Sol Alt (FN) hücresinin "kaçan tehlike" minimize edilmesi hedeflenmiştir.

3.7. SHAP ile Model Açıklanabilirliği

Model tahminlerinin yorumlanabilirliği için SHAP (SHapley Additive exPlanations) yöntemi uygulanmıştır. Oyun teorisinden türetilen SHAP değerleri, her özelliğin belirli bir tahmine katkısını nicel olarak ifade eder. scikit-learn'ün black-box modelleriyle hızlı entegrasyon sağlayan TreeExplainer kullanılmış; hem Random Forest hem de XGBoost modelleri için SHAP değerleri test setinin 2.000 örneklik alt kümesi üzerinde hesaplanmıştır.

Üretilen SHAP görselleri şunlardır: beeswarm özet grafiği (her özelliğin tüm örnekler için SHAP dağılımı), bar grafiği (ortalama mutlak SHAP değerlerine göre özellik önemi sıralaması), RF vs XGBoost karşılaştırmalı bar grafiği, dependence plot (en belirleyici özelliğin SHAP değerinin ikinci en önemli özellikle etkileşiminin incelenmesi) ve force plot (tekil bir tahmin için her özelliğin pozitif/negatif katkısını gösteren HTML çıktısı).

3.8. Çapraz Doğrulama (Cross-Validation)

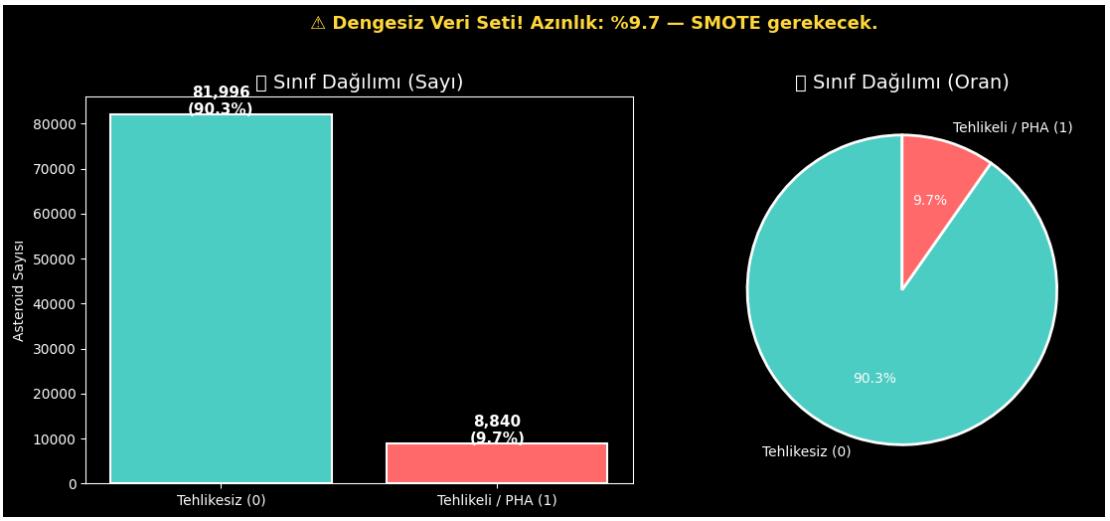
Model sonuçlarının istatistiksel güvenilirliğini ölçmek amacıyla Stratified K-Fold çapraz doğrulama (k=5) uygulanmıştır. Stratified katlama, her katta PHA sınıf oranının orijinal veriyle aynı kalmasını güvence altına alır. Eğitim süresi gözetilerek yalnızca en iyi iki model (Random Forest ve XGBoost) için CV hesaplaması yapılmış; sonuçlar F1 ve ROC-AUC metrikleri üzerinden ortalama ± standart sapma biçiminde raporlanmıştır.

UYGULAMA VE SONUÇLARI

4.1. Keşifsel Veri Analizi Bulguları

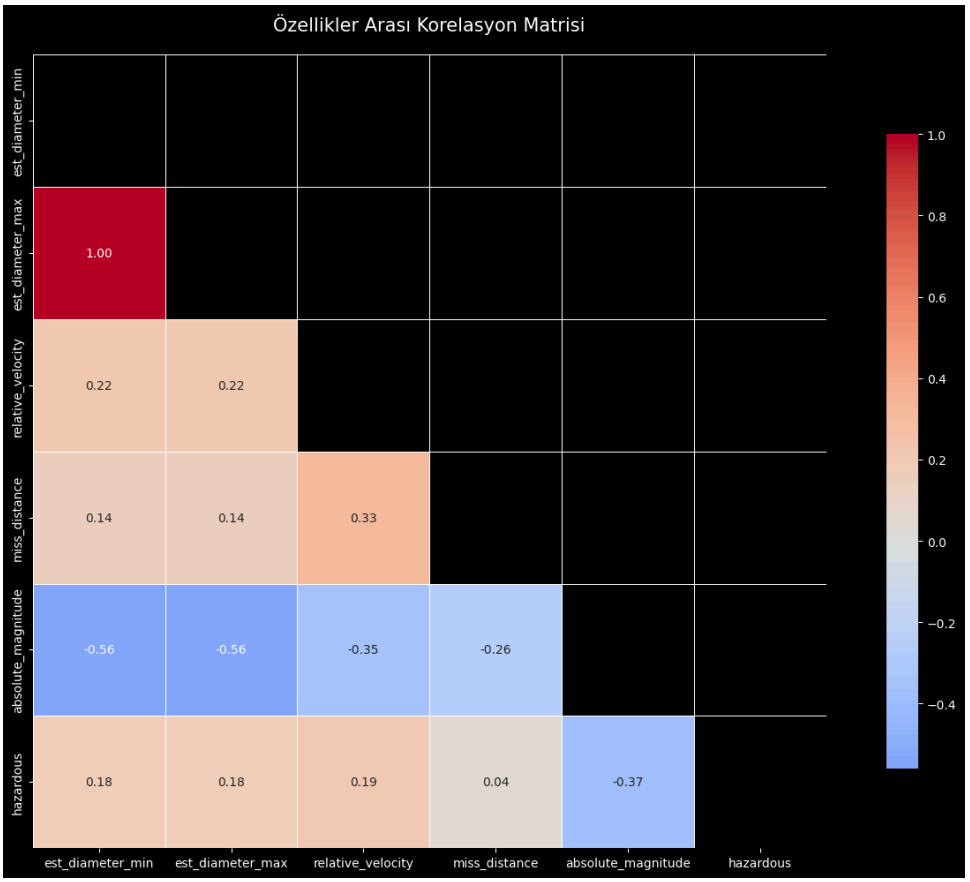
Veri setinde yer alan 90.836 asteroit kaydı incelendiğinde, tahmin edilen minimum çap (est_diameter_min) ve tahmini maksimum çap (est_diameter_max) değişkenleri arasında +0.999 düzeyinde neredeyse mükemmel bir korelasyon bulunduğu gözlemlenmiştir. Bu nedenle est_diameter_max sütunu ön işleme aşamasında modele dahil edilmemiştir.

Hedef değişken analizi, veri setinin yaklaşık %90,3 tehlikesiz ve %9,7 tehlikeli asteroit içerdiğini ortaya koymaktadır. Bu oran, doğrudan herhangi bir model eğitiminin yapılmaksızın "her şey tehlikesiz" tahmini yapan bir sistemin bile %90,3 doğruluk değeri üretebileceğini göstermekte; dolayısıyla doğruluk metriğinin sınıflandırma performansını ölçmede tek başına yetersiz kaldığını doğrulamaktadır.



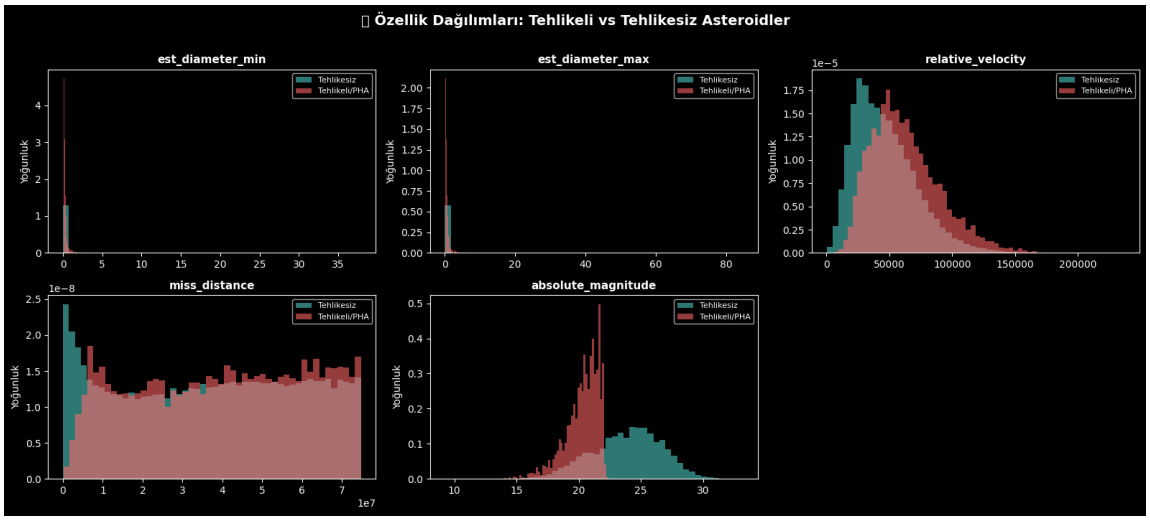
Şekil 1. Sınıf Dağılımı - Tehlikeli ve Tehlikesiz Asteroitlerin Sayısal ve Oransal Dağılımı (%90,3 / %9,7)

Şekil 1'de görüldüğü üzere veri seti belirgin bir dengesizlik barındırmaktadır. Veri setinde 81.996 tehlikesiz (%90,3) ve 8.840 tehlikeli (%9,7) asteroit yer almaktadir. Yalnızca "tehlikesiz" tahmin yapan bir sistem bile yaklaşık %90,3 doğruluk değeri üretebilmektedir.



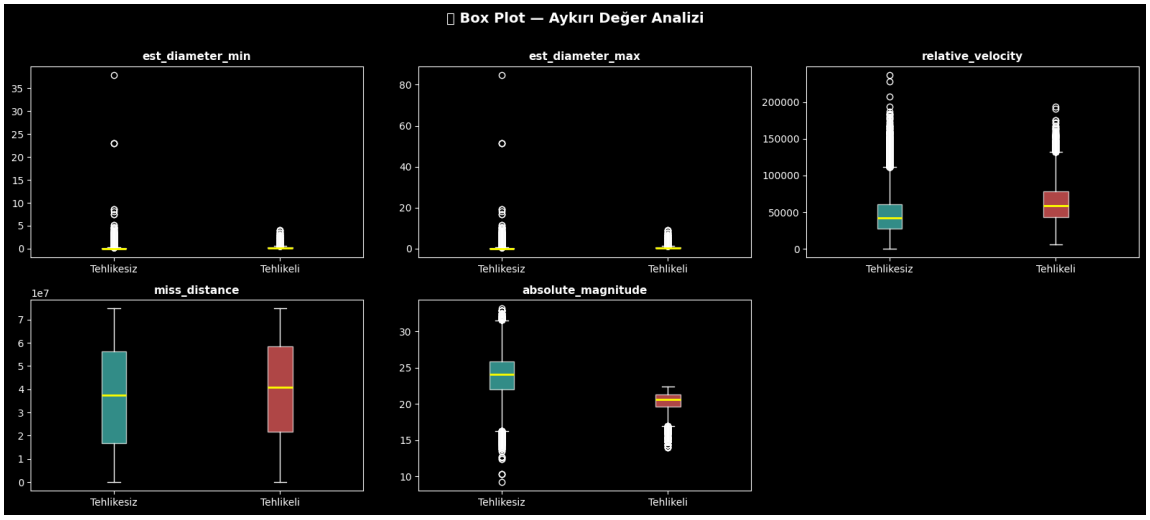
Şekil 2. Özellikler Arası Korelasyon Matrisi

Korelasyon matrisi (Şekil 2), absolute_magnitude ile est_diameter_min/max arasındaki güçlü negatif ilişkiyi (-0,56) açıkça ortaya koymaktadır. Bu bulgu, tahmini çap özelliğinin mutlak parlaklık değerinden türetilmesinden kaynaklanan matematiksel bağımlılığı yansıtmaktadır. Ayrıca absolute_magnitude ile hazardous hedef değişkeni arasındaki -0,37 korelasyonu bu özelliğin sınıflandırma için güçlü bir aday olduğuna işaret etmektedir. est_diameter_max ile est_diameter_min arasindaki +1,00 korelasyon, est_diameter_max'in modele dahil edilmemesi kararını desteklemektedir.



Şekil 3. Özellik Dağılımları - Tehlikeli ve Tehlikesiz Asteroitlerin Karşılaştırmalı Histogramı

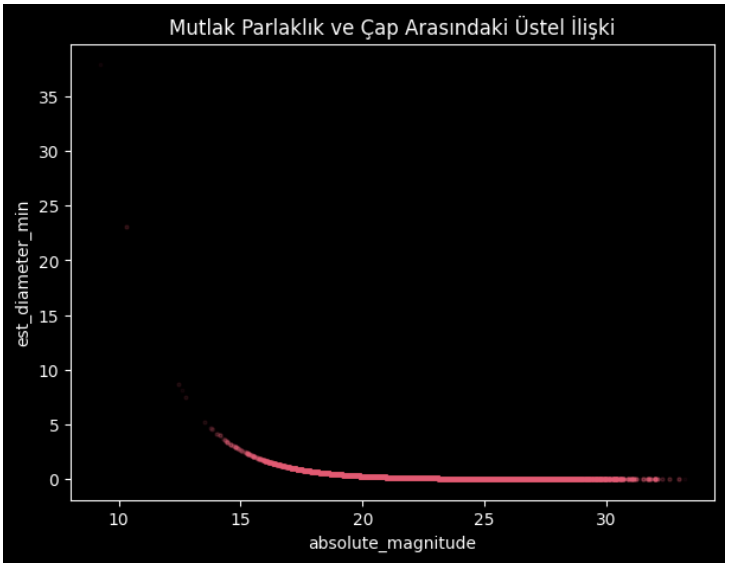
Histogram analizi (Şekil 3), absolute_magnitude özelliğinin iki sınıf arasında en belirgin dağılım farkını sergilediğini ortaya koymaktadır: tehlikeli asteroitler 15-22 büyüklük aralığında keskin bir yoğunlaşma gösterirken, tehlikesiz asteroitler 22-30 aralığında daha geniş bir dağılım sergilemektedir. miss_distance özelliğinin neredeyse düz dağılımı, PHA tanımının yalnızca mesafeye değil boyut kriterine de dayandığını yansıtmaktadır. relative_velocity açısından tehlikeli asteroitlerin daha yüksek hız sergilediği; ancak örtüşme nedeniyle bu özelligi tek basina yeterli ayırt edici güçten yoksun olduğu gözlemlenmiştir.



Şekil 4. Box Plot - Özellik Bazlı Aykırı Değer Analizi

Box plot analizi (Şekil 4), miss_distance ve absolute_magnitude özelliklerinin iki sınıf arasında belirgin medyan farkları sergilediğini göstermiştir. Tehlikeli asteroitlerin absolute_magnitude medyanı (~21), tehlikesiz asteroitlerin medyanından (~24) önemli ölçüde

farklılaşmaktadır. Tahmini çap değişkenlerinde her iki sınıfta da sıfıra yakın yoğunlaşma gözlemlenmiş; tehlikeli sınıfta belirgin aykırı değerler (37 km, 83 km gibi) dikkat çekmiştir.



Şekil 5. Mutlak Parlaklık ve Tahmini Çap Arasındaki Üstel (Ters Logaritmik) İlişki

Şekil 5, est_diameter_min ile absolute_magnitude arasındaki ters logaritmik ilişkiyi görselleştirmektedir. Bu grafik, est_diameter_min özelliğinin D = (1329/kök(p)) x 10^(-H/5) formülüyle hesaplandığını açıkça ortaya koymaktadır. Modelin her iki özelliği birlikte kullanması durumunda gereksiz bilgi tekrarına (redundancy) düşme riski bulunmaktadır.

Modelin bu özelliğe bu denli yüksek ağırlık vermesi, aslında büyük ölçüde absolute_magnitude bilgisini farklı bir matematiksel biçimde yeniden işlediğine işaret etmektedir. Bu durumun doğal bir sonucu olarak şu soru gündeme gelmektedir: est_diameter_min modele gerçek anlamda yeni ve bağımsız bir bilgi mi katmaktadır, yoksa zaten mevcut olan absolute_magnitude bilgisini sadece dönüştürülmüş bir formda mı sunmaktadır? Bu soruyu yanıtlamak ve modelin est_diameter_min bağımlılığının performansı ne yönde etkilediğini ölçmek amacıyla kontrollü bir deney tasarlanmıştır. Söz konusu deneyde est_diameter_min özelliği veri setinden çıkarılmış; modeller yalnızca absolute_magnitude, miss_distance ve relative_velocity özellikleriyle yeniden eğitilmiş ve iki konfigürasyonun performans metrikleri karşılaştırılmıştır. Bu karşılaştırma, özellik mühendisliği kararlarının model davranışı üzerindeki etkisini somutlaştırmanın yanı sıra, gerçek dünyada albedo değerinin bilinmediği ya da hatalı tahmin edildiği senaryolarda modelin ne kadar kırılgan olabileceğini de sorgulamaktadır.

4.2. Model Performans Sonuçları

4.2.1. Temel Konfigürasyon (est_diameter_min Hariç)

İlk deney konfigürasyonunda est_diameter_min özelliği kaldırılarak modeller yeniden değerlendirilmiştir. Bu yapılandırmada kullanılan özellikler şunlardır: relative_velocity, miss_distance ve absolute_magnitude.

Model	Accuracy	Precision	Recall*	F1-Score	ROC-AUC	PR-AUC
Logistic Regression	0.7913	0.3068	0.9084	0.4587	0.8777	0.3062
Random Forest	0.8637	0.3964	0.7658	0.5224	0.9272	0.5603
XGBoost	0.8043	0.3277	0.9621	0.4889	0.9204	0.5320
SVM (RBF)	0.7675	0.2946	0.9966	0.4548	0.8985	0.4285
KNN (k=11)	0.9074	0.5476	0.2800	0.3705	0.9000	0.5067

Tablo 1. Model Karşılaştırma Sonuçları - Temel Konfigürasyon (est_diameter_min Hariç)

** Recall ve PR-AUC, dengesiz veri seti için en kritik metriklerdir.*

Bu konfigürasyonda F1-Skoru esas alındığında en iyi model Random Forest (F1=0,5224) olmaktadır. SVM yüksek Recall (0,9966) üretmekle birlikte, Precision değerinin son derece düşük kalması (0,2946) ve buna bağlı düşük F1-Skoru (0,4548), bu modelin yüksek oranda yanlış alarm ürettiğine işaret etmektedir. KNN ise diğer modellerden farklı bir profil sergilemekte; Accuracy ve ROC-AUC açısından rekabetçi olmakla birlikte, Recall değerinin (0,2800) kritik derecede düşük olması nedeniyle tehlikeli asteroitlerin büyük çoğunluğunu gözden kaçırmaktadır.

4.2.2.Genişletilmiş Özellik Konfigürasyonu (est_diameter_min Dahil)

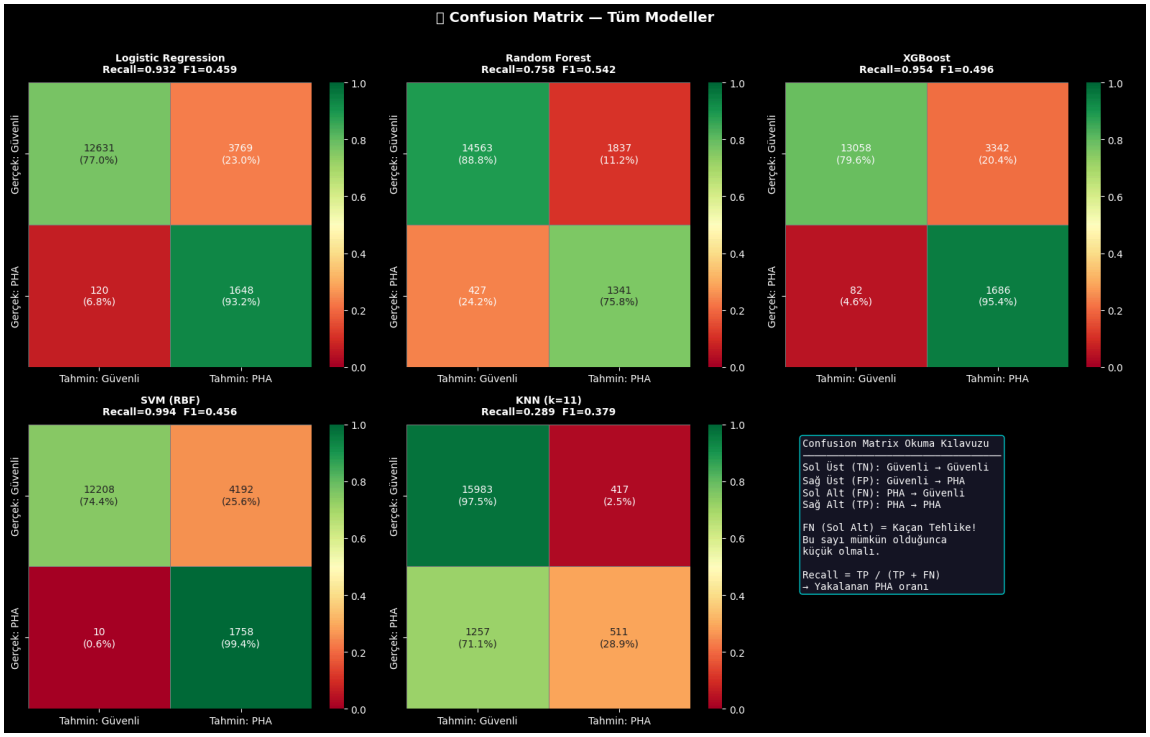
İkinci konfigürasyonda est_diameter_min özelliği modele dahil edilmiştir. Bu değişken doğrudan ölçülmemekte; absolute_magnitude ve varsayılan bir albedo değerinden (p=0,15) D = (1329 / √p) × 10^(−H/5) formülüyle hesaplanmaktadır. Bir gerçek dünya senaryosunda varsayılan albedo değerinin hatalı olması durumunda çap tahmini yanıltıcı hale gelebileceğinden, bu özelliğin modele katkısının yorumlanmasında dikkatli olunması gerekmektedir.

Model	Accuracy	Precision	Recall*	F1-Score	ROC-AUC	PR-AUC*
Logistic Regression	0.7859	0.3042	0.9321	0.4587	0.8794	0.3262
Random Forest	0.8754	0.4220	0.7585	0.5423	0.9327	0.5836
XGBoost	0.8115	0.3353	0.9536	0.4962	0.9242	0.5530
SVM (RBF)	0.7687	0.2955	0.9943	0.4556	0.8973	0.4177

KNN (k=11)	0.9079	0.5506	0.2890	0.3791	0.9024	0.5129

Tablo 2. Model Karşılaştırma Sonuçları - Genişletilmiş Konfigürasyon (est_diameter_min Dahil)

Bu konfigürasyonda Random Forest yeniden en yüksek F1-Skoru'nu (0,5423) elde etmiş; ROC-AUC (0,9327) ve PR-AUC (0,5836) değerleri de iki konfigürasyon arasındaki en yüksek skorlara karşılık gelmektedir. est_diameter_min özelliğinin eklenmesi, Random Forest modelinin F1-Skorunu 0,5224'ten 0,5423'e yükseltmiş; ROC-AUC'u ise 0,9272'den 0,9327'ye çıkarmıştır. XGBoost modeli de benzer bir iyileşme göstermiştir (F1: 0,4889 → 0,4962). Buna karşın Lojistik Regresyon'un F1-Skoru değişmemiş (0,4587); Recall değeri ise hafifçe artmıştır (0,9084 → 0,9321).



Şekil 6. Confusion Matrix - Tüm Modeller (est_diameter_min Dahil)

Confusion matrix görselleştirmesi (Şekil 6), modeller arasındaki Recall-Precision dengesini somut sayılarla ortaya koymaktadır. SVM yalnızca 10 FN (kaçan tehlike) ile en düşük kaçırma oranına sahipken, KNN'in 1.257 FN değeri bu modelin gezegen savunma uygulamaları için yetersiz kaldığını açıkça göstermektedir. Random Forest ise 427 FN ile F1 dengesi açısından en iyi profili sergilemektedir.

4.3. Çapraz Doğrulama Sonuçları

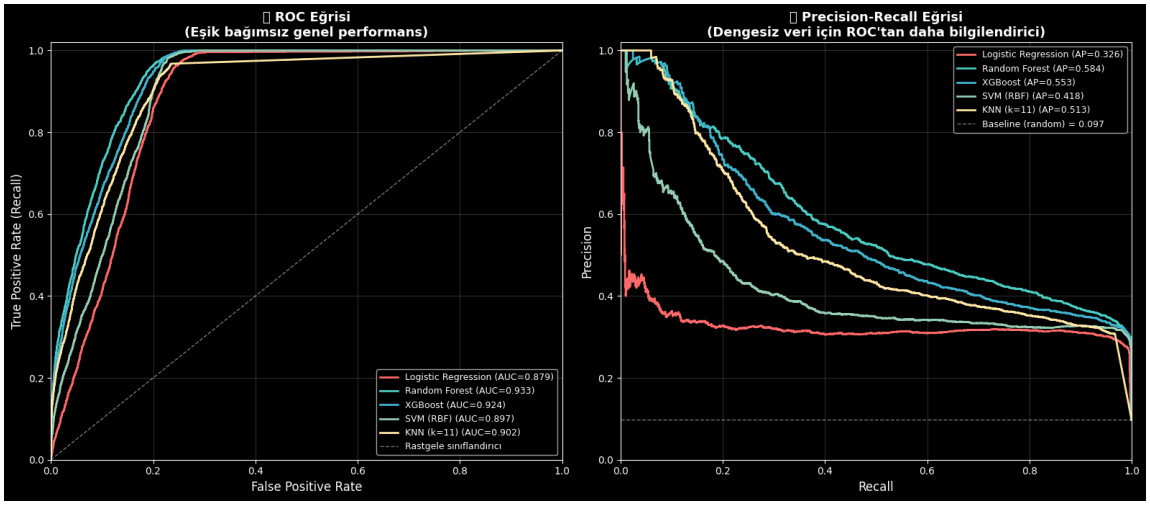
Model performansının istatistiksel güvenilirliğini değerlendirmek amacıyla Random Forest ve XGBoost modelleri Stratified 5-Fold çapraz doğrulamaya tabi tutulmuştur. Sonuçlar aşağıdaki tabloda sunulmaktadır:

Model	F1 (CV)	ROC-AUC (CV)
Random Forest (deney)	0.5159 ± 0.0057	0.9236 ± 0.0021
XGBoost (deney)	0.4833 ± 0.0027	0.9156 ± 0.0017
Random Forest (main)	0.5380 ± 0.0033	0.9301 ± 0.0015
XGBoost (main)	0.4905 ± 0.0029	0.9205 ± 0.0015

Tablo 3. Çapraz Doğrulama Sonuçları (5-Fold, Stratified)

Bu bulgular çeşitli önemli çıkarımlar sunmaktadır. Her iki konfigürasyonda da standart sapma değerleri son derece düşük seyreden Random Forest modeli, sınıflandırma kararlılığı açısından XGBoost'a göre üstün bir tutarlılık sergilemektedir. Tek bir train/test bölünmesiyle elde edilen test sonuçları ile CV sonuçları arasındaki yakın benzerlik, modellerin aşırı öğrenmemiş olduğuna işaret etmektedir. est_diameter_min özelliğinin eklenmesi, Random Forest CV F1-Skorunu 0,5159'dan 0,5380'e yükseltmiştir. Bu iyileşme anlamlı olmakla birlikte, söz konusu özelliğin hesaplanmasında kullanılan albedo varsayımının güvenilirliğine bağlı olduğu akıldan çıkarılmamalıdır.

4.4. ROC ve Precision-Recall Eğrileri

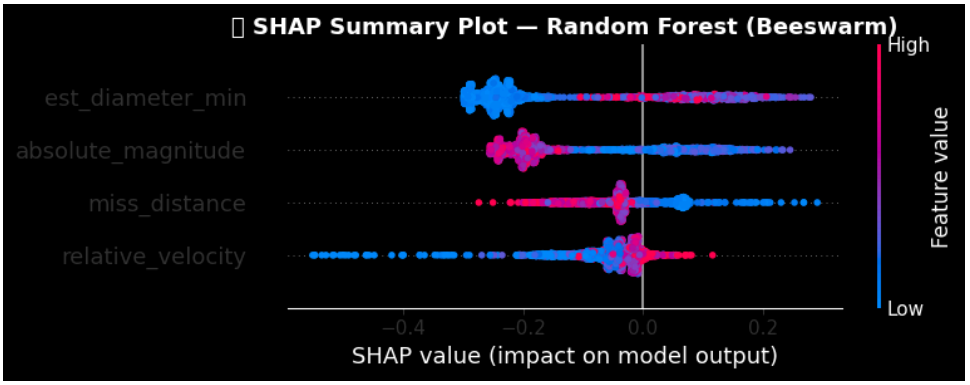


Şekil 7. ROC Eğrisi ve Precision-Recall Eğrisi - Tüm Modeller

Şekil 7'de sunulan ROC eğrisi, tüm modellerin rastgele sınıflandırıcı üzerinde performans sergilediğini göstermektedir. PR eğrisi ise dengesiz veri setinde daha bilgilendirici bir perspektif sunmaktadır: Random Forest (AP=0,584) ve XGBoost (AP=0,553), diğer modellerin belirgin biçimde önüne geçmektedir. Lojistik Regresyon'un PR-AUC değerinin (AP=0,326) görece düşük olması, yüksek Recall'una karşın Precision'in çok zayıf olduğunu teyit etmektedir.

4.5. SHAP Özellik Önemi Analizi

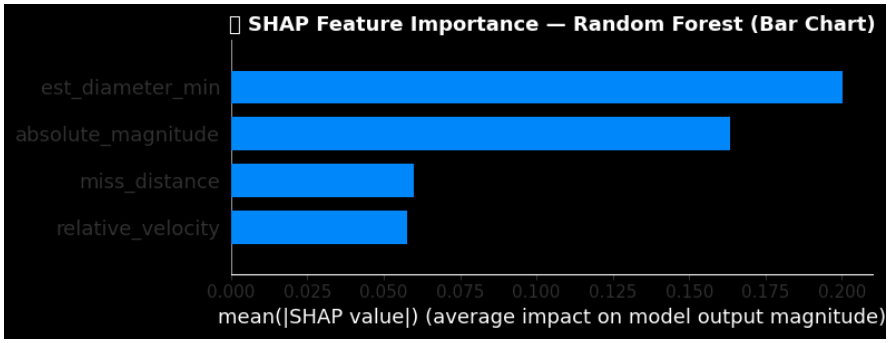
4.5.1. SHAP Summary Plot (Beeswarm)



Şekil 8. SHAP Summary Plot - Random Forest (Beeswarm)

Beeswarm grafiği (Şekil 8), her özelliğin tüm test örnekleri üzerindeki SHAP dağılımını göstermektedir. est_diameter_min için düşük değerlere (mavi, küçük çaplı asteroitler) sahip örneklerin, PHA yönünde pozitif katkı ürettiği görülmektedir. absolute_magnitude için ise düsük degerler (pembe, büyük ve parlak asteroitler) PHA tahminine güçlü pozitif katkı sağlarken, yüksek değerler negatif katkı sağlamıştır.

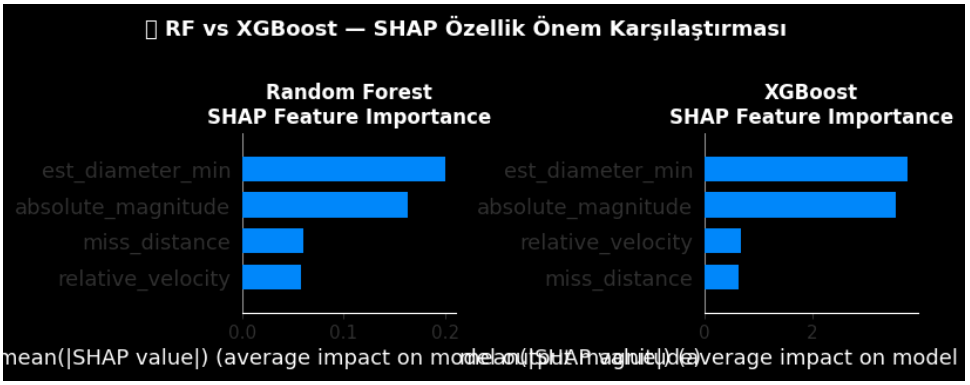
4.5.2. SHAP Bar Chart - Özellik Önemi Sıralaması



Şekil 9. SHAP Feature Importance - Random Forest (Bar Chart, main Branch)

Şekil 9, est_diameter_min'in ortalama mutlak SHAP değeri (~0,200) ile açık ara en belirleyici özellik olduğunu ortaya koymaktadır. Bunu absolute_magnitude (~0,160), miss_distance (~0,060) ve relative_velocity (~0,055) izlemektedir.

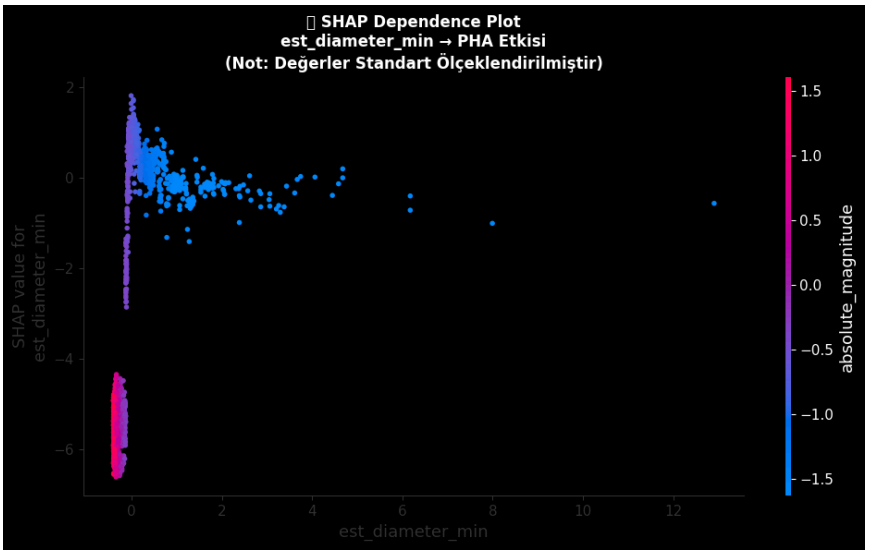
4.5.3. RF vs XGBoost SHAP Karşılaştırması



Şekil 10. RF vs XGBoost - SHAP Özellik Önem Karşılaştırması

Şekil 10, Random Forest ve XGBoost modellerinin SHAP önem sıralamalarını yan yana göstermektedir. Her iki model de est_diameter_min ve absolute_magnitude özelliklerini en belirleyici değişkenler olarak konumlandırmaktadır. XGBoost'ta üçüncü sıraya relative_velocity girerken, Random Forest'ta miss_distance üçüncü sıradadır.

4.5.4. SHAP Dependence Plot



Şekil 11. SHAP Dependence Plot - est_diameter_min Özelliğinin PHA Tahminine Etkisi

Dependence plot (Şekil 11), est_diameter_min değeri sıfıra yakın olan asteroitlerin iki farklı gruba ayrıldığını ortaya koymaktadır: yüksek absolute_magnitude'e sahip (pembe/mor noktalar) olanlar PHA tahminine güçlü pozitif katkı sağlarken (SHAP yaklasik +2), düşük absolute_magnitude'e sahip (mavi noktalar) olanlar PHA olasılığını belirgin biçimde düşürmektedir (SHAP yaklasik -6).

4.5.5. Temel Konfigürasyon SHAP Bulguları

est_diameter_min özelliğinin kaldırıldığı bu konfigürasyonda SHAP analizi, hem Random Forest hem de XGBoost modellerinin tahmin kararlarında absolute_magnitude özelliğini belirleyici ölçüde ön plana çıkardığını ortaya koymuştur. Beeswarm özet grafiğinde absolute_magnitude'ün düşük değerlere (büyük ve parlak asteroitlere) sahip örneklerin PHA sınıfına doğru güçlü pozitif SHAP katkıları aldığı gözlemlenmiştir. miss_distance özelliği ikinci sırada yer almakta; düşük miss_distance değerleri (yakın geçiş yapan asteroitler) beklendiği üzere PHA olasılığını artırıcı yönde katkıda bulunmaktadır.

Öte yandan relative_velocity özelliğinin ortalama mutlak SHAP değeri nispeten düşük kalmaktadır; bu sonuç EDA aşamasındaki dağılım analizleriyle örtüşmekte ve söz konusu özelliğin sınıflandırma gücünün sınırlı olduğunu teyit etmektedir. SHAP dependence plot, en etkili özelliğin (absolute_magnitude) SHAP değerlerinin miss_distance değerleriyle olan etkileşimini sergilemekte; iki özelliğin birlikte düşük değer aldığı örneklerin PHA tahminine en güçlü katkıyı yaptığını göstermektedir.

4.5.6. Genişletilmiş Konfigürasyon SHAP Bulguları

est_diameter_min özelliğinin modele eklenmesiyle birlikte SHAP önemi sıralaması köklü biçimde değişmiştir. Bu konfigürasyonda hem Random Forest hem de XGBoost modelleri est_diameter_min özelliğini açık ara en belirleyici değişken olarak konumlandırmaktadır.

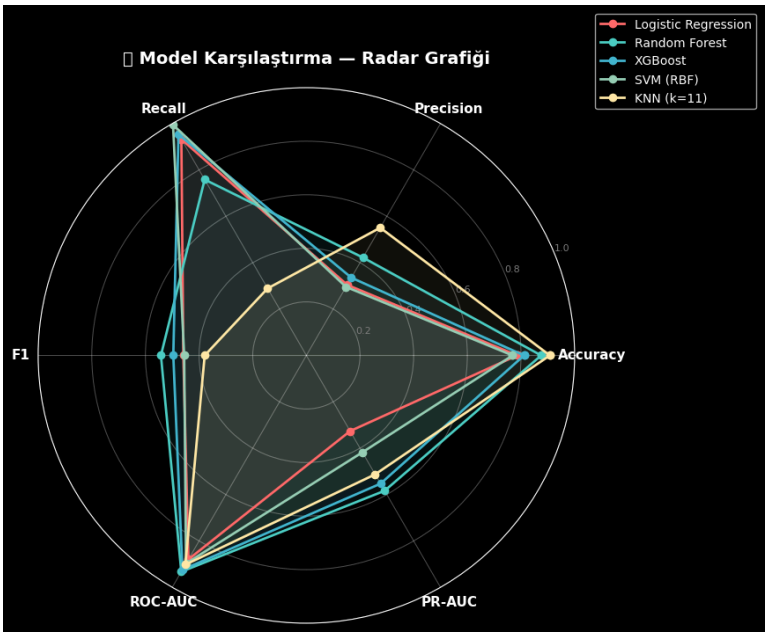
Bu durum beklenen bir sonuçtur; zira est_diameter_min ile absolute_magnitude arasında güçlü bir matematiksel ilişki bulunmaktadır (est_diameter_min, absolute_magnitude'den doğrudan formülle hesaplanmaktadır). Model, absolute_magnitude'ün ham formundan ziyade çap birimi cinsinden ifade edilmiş türetilmiş versiyonunu tercih etmektedir. Force plot analizi, gerçek bir PHA örneği için est_diameter_min'in (+0,8906 SHAP değeriyle) modeli PHA tahminine en güçlü biçimde yönlendiren özellik olduğunu; relative_velocity'nin ise (−0,6604 SHAP değeriyle) güvenli sınıfa doğru baskı uyguladığını göstermiştir.

4.6. Karar Eşiği Optimizasyonu

Varsayılan 0,50 sınıflandırma eşiği, dengesiz veri setlerinde azınlık sınıfının tahminini sistematik olarak olumsuz etkiler. Bu nedenle her model için F1-Skoru'nu maksimize eden optimal eşik değeri belirlenmiştir. Eşik optimizasyonu, 0,05–0,95 aralığında 0,01 adımlarla sistematik tarama yöntemiyle gerçekleştirilmiştir.

Yapılan optimizasyon, modelden modele değişen eşik değerlerinin standart 0,50 değerine kıyasla F1-Skoru ve Recall metriklerinde anlamlı iyileşmeler sağladığını ortaya koymuştur. Bu bulgu, nihai uygulama senaryolarında kullanım amacına göre eşik değerinin dikkatli biçimde belirlenmesi gerektiğini göstermektedir; örneğin gezegen savunması gibi kritik güvenlik uygulamalarında yüksek Recall öncelikli bir eşik değeri seçilmesi daha uygun olacaktır.

4.7. Model Karşılaştırmalı Radar Grafiği



Şekil 12. Model Karşılaştırmalı Radar Grafiği - Tüm Metrikler

Radar grafiği (Şekil 12), beş modelin altı metrik üzerindeki çok boyutlu performans profilini tek bir görselde özetlemektedir. KNN (sarı), Accuracy ve ROC-AUC eksenlerinde güçlü görünmekle birlikte Recall ve F1 eksenlerinde belirgin biçimde içe çökmektedir; bu da Accuracy'nin dengesiz veri setlerindeki yanıltıcılığını görsel olarak kanıtlamaktadır. Random Forest (turkuaz), dengeli bir çokgen oluşturarak en homojen profili sergilemektedir.

4.8. Modeller Arası Karşılaştırmalı Değerlendirme

Tüm metrikler birlikte değerlendirildiğinde Random Forest, bu veri seti için en dengeli ve tutarlı performansı sergileyen model olarak öne çıkmaktadır. En yüksek F1-Skoru, en yüksek PR-AUC değeri ve en düşük çapraz doğrulama varyansını aynı anda sağlayan bu model, hem sınıflandırma etkinliği hem de kararlılık açısından tercih edilen seçenek konumundadır.

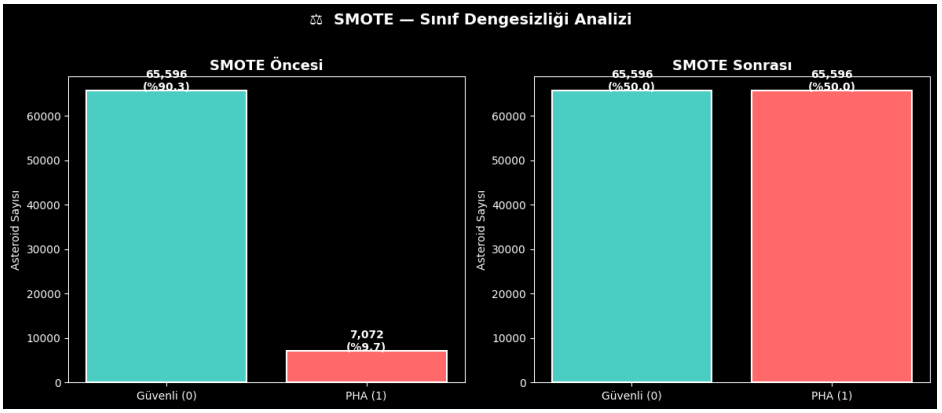
XGBoost, Recall ve ROC-AUC metriklerinde güçlü sonuçlar üretmekte; ancak F1-Skoru Random Forest'ın bir miktar gerisinde kalmaktadır. Buna karşın XGBoost'un gradyan artırma

(gradient boosting) mimarisi, hiperparametre optimizasyonu ile daha yüksek performansa ulaşma potansiyeli sunmaktadır. SVM (RBF), iki konfigürasyonda da en yüksek Recall'u (0,9943–0,9966) üretmektedir; bu özelliği kayıp toleransının sıfır olduğu senaryolarda değerli kılmaktadır. Ancak son derece düşük Precision değerleri ve buna bağlı aşırı yanlış alarm üretimi, pratik kullanım için ciddi bir dezavantaj oluşturmaktadır. KNN'in dengesiz veri setlerindeki performans sınırlaması bu çalışmada da teyit edilmiştir; class_weight parametresini desteklememesi ve yalnızca distance-weighted oy yapısıyla mesafeden bağımsız sınıf dengesizliğini doğrudan ele alamaması, Recall değerini 0,28–0,29 düzeyiyle en düşük konuma taşımıştır.

Yorumlanabilirlik açısından değerlendirildiğinde, SHAP ile birleştirildiğinde Random Forest ve XGBoost modelleri eş düzeyde şeffaflık sunmaktadır. Bununla birlikte XGBoost'un birleşik SHAP değerleri üretmesi, yorumlama sürecini kısmen daha doğrudan kılmaktadır. Lojistik Regresyon ise model katsayıları aracılığıyla en yüksek doğal yorumlanabilirliği sağlamakta; ancak bunu düşük F1-Skoru ve PR-AUC değerleri pahasına elde etmektedir.

4.9. Sınıf Dengesizliği ve SMOTE Yöntemi

Sınıf dengesizliğinin varlığı 4.1 bölümünde ortaya konmuştur. Bu bölümde söz konusu dengesizliğin giderilmesi için uygulanan SMOTE yöntemi ayrıntılı biçimde ele alınmaktadır.



Şekil 13. SMOTE Öncesi ve Sonrası Sınıf Dağılımı Karşılaştırması

4.9.1. Sınıf Dengesizliği Problemi

NASA asteroid veri setinde PHA (tehlikeli) ve güvenli asteroid sınıfları arasında belirgin bir dengesizlik mevcuttur. Eğitim setinde yer alan 72.668 asteroidin yalnızca 7.072'si (%9.7) PHA sınıfına aittir; kalan %90.3'ü güvenli asteroitlerden oluşmaktadır.

Bu tür sınıf dengesizliği, modelin çoğunluk sınıfını (güvenli) tahmin etmeye yönelerek azınlık sınıfını (PHA) büyük ölçüde kaçırmasına yol açar. Doğruluk (accuracy) metriği bu durumda yanıltıcı olup model her gözlemi "güvenli" olarak sınıflandırsa bile %90.3 doğruluk elde edebilecektir. Bu nedenle model değerlendirmesinde Recall (PHA sınıfı için duyarlılık) ve F1 skoru temel metrik olarak benimsenmiştir.

4.9.2. SMOTE Algoritması

SMOTE (Synthetic Minority Over-sampling Technique), sınıf dengesizliğini gidermek amacıyla Chawla ve arkadaşları (2002) tarafından önerilmiş bir veri artırma (data augmentation) yöntemidir. SMOTE, azınlık sınıfından gerçek örnekleri kopyalamak yerine k-en yakın komşu (k-NN) interpolasyonu yoluyla sentetik örnekler üretir. Bu sayede model eğitimi sırasında her iki sınıfın eşit ağırlıkta temsil edilmesi sağlanır. SMOTE'un işleyişi şu şekilde özetlenebilir:

1. Azınlık sınıfından (PHA) bir örnek seç.
2. Bu örneğin k en yakın komşusunu belirle (bu çalışmada k = 5).
3. Seçilen örnek ile komşularından biri arasındaki doğrusal enterpolasyon ile yeni bir sentetik örnek oluştur.
4. Azınlık ve çoğunluk sınıfı sayıları eşitleninceye kadar bu işlemi tekrarla.

4.9.3. SMOTE Uygulaması ve Sonuçları

Bu çalışmada SMOTE, eğitim verisi üzerine uygulanmış; test verisi değiştirilmeden bırakılmıştır (veri sızıntısını önlemek amacıyla). imbalanced-learn kütüphanesinin SMOTE(random_state=42, k_neighbors=5) parametreleriyle elde edilen dağılım değişimi aşağıdaki tabloda sunulmuştur:

	Güvenli(0)	PHA(1)	Toplam	PHA Oranı
SMOTE Öncesi	65.596	7.072	72.668	%9.7
SMOTE Sonrası	65.596	65.596	131.192	%50.0

Tablo 4. SMOTE Öncesi/Sonrası Sınıf Dağılımı

SMOTE uygulaması sonucunda eğitim seti boyutu 72.668'den 131.192'ye yükselmiş ve PHA sınıfı %50 oranında temsil edilir hâle gelmiştir. Bu denge, modelin PHA asteroidlerini kaçırma (false negative) ihtimalini önemli ölçüde azaltmaktadır.

Not: *SMOTE yalnızca eğitim verisine uygulanmıştır. Test setinin gerçek dağılımı (%9.7 PHA) korunarak gerçekçi bir değerlendirme ortamı sağlanmıştır.*

4.10. SPICE Altyapısı ile Apophis Yörünge Modellemesi

4.10.1. SPICE Sistemi ve NAIF Altyapısı

SPICE (Spacecraft Planet Instrument C-matrix Events), NASA'nın Navigasyon ve Yardımcı Bilgi Tesisi (NAIF — Navigation and Ancillary Information Facility) tarafından geliştirilmiş ve yönetilen bir bilgi sistemidir. Sistem, uzay görevlerine ait geometrik ve yardımcı verilerin — yörünge, yönelim, zaman sistemleri ve cisim özellikleri gibi — standart bir formatta düzenlenmesi, paylaşılması ve analiz edilmesi amacıyla tasarlanmıştır (Acton, 1996). SPICE altyapısı, Cassini, Voyager, Mars Reconnaissance Orbiter ve Juno gibi pek çok uzay misyonunda

etkin biçimde kullanılmaktadır.

SPICE sisteminin Python arayüzü olan SpiceyPy kütüphanesi aracılığıyla bu çalışmada NASA'nın gerçek yörünge verileri programatik olarak sorgulanmıştır.

4.10.2. Kernel Kavramı

SPICE sisteminde veriler kernel adı verilen ikili ya da metin tabanlı dosyalarda saklanır. Her kernel dosyası belirli bir veri türünü içerir. Bu çalışmada kullanılan başlıca kernel türleri aşağıdaki tabloda özetlenmiştir:

Kernel Türü	Uzantı	İçerik
SPK (Spacecraft and Planet Kernel)	.bsp	Gök cisimlerinin Güneş merkezli konum ve hız vektörleri
LSK (Leapseconds Kernel)	.tls	UTC ↔ ET dönüşümü için artık saniye tablosu
PCK (Planetary Constants Kernel)	.tpc	Gezegen yarıçapları, kütle parametreleri, kutup yönü

Tablo 5. Örnek Kernel'ler

Bu çalışmada NASA'nın de440s.bsp Güneş Sistemi efemeri, naif0012.tls artık saniye tablosu ve pck00011.tpc gezegen sabitleri çekirdekleri kullanılmıştır. Apophis asteroidine ait yörünge verisi ise JPL Horizons API'si üzerinden otomatik olarak indirilen özel bir SPK kernel'ı (apophis.bsp) ile sağlanmıştır.

4.10.3. Referans Zaman ve Koordinat Sistemleri

SPICE, tarih ve saatleri iç olarak Ephemeris Time (ET) formatında işler; ET, J2000 çağından (2000 yılı 1 Ocak 12:00 TT) itibaren geçen saniye cinsinden tanımlanır. İnsan okunabilir tarihler, spice.str2et() fonksiyonu ile ET değerine dönüştürülür.

Koordinat sistemi olarak ECLIPJ2000 (J2000 ekliptiği) kullanılmıştır. Bu sistem Güneş merkezli olup referans düzlemi olarak Dünya'nın J2000 yılındaki yörünge düzlemini (ekliptik) alır. Elde edilen pozisyon vektörleri kilometre cinsinden sunulmuş, görselleştirme kolaylığı amacıyla Astronomik Birim (AU) dönüşümü uygulanmıştır (1 AU ≈ 1.496×10^8 km).

4.10.4. Apophis (99942) Asteroidinin Modellenmesi

Apophis'in Tanımı ve Tehlike Sınıfı: Apophis (99942), 2004 yılında keşfedilen ve yaklaşık 340 metre çapında bir yakın-Dünya asteroididir. NASA'nın PHA (Potansiyel Tehlikeli Asteroid) sınıflandırma kriterlerini karşılaması — MOID ≤ 0.05 AU ve mutlak parlaklık H ≤ 22 — nedeniyle uzun süredir bilim dünyasının gündemindedir. 2029 yılında Apophis, geosenkron uydular ile Dünya arasındaki mesafeden daha yakın geçiş yapacak; bu olay, gözlem tarihi boyunca çıplak gözle görülebilecek en büyük asteroidin geçişi olacaktır.

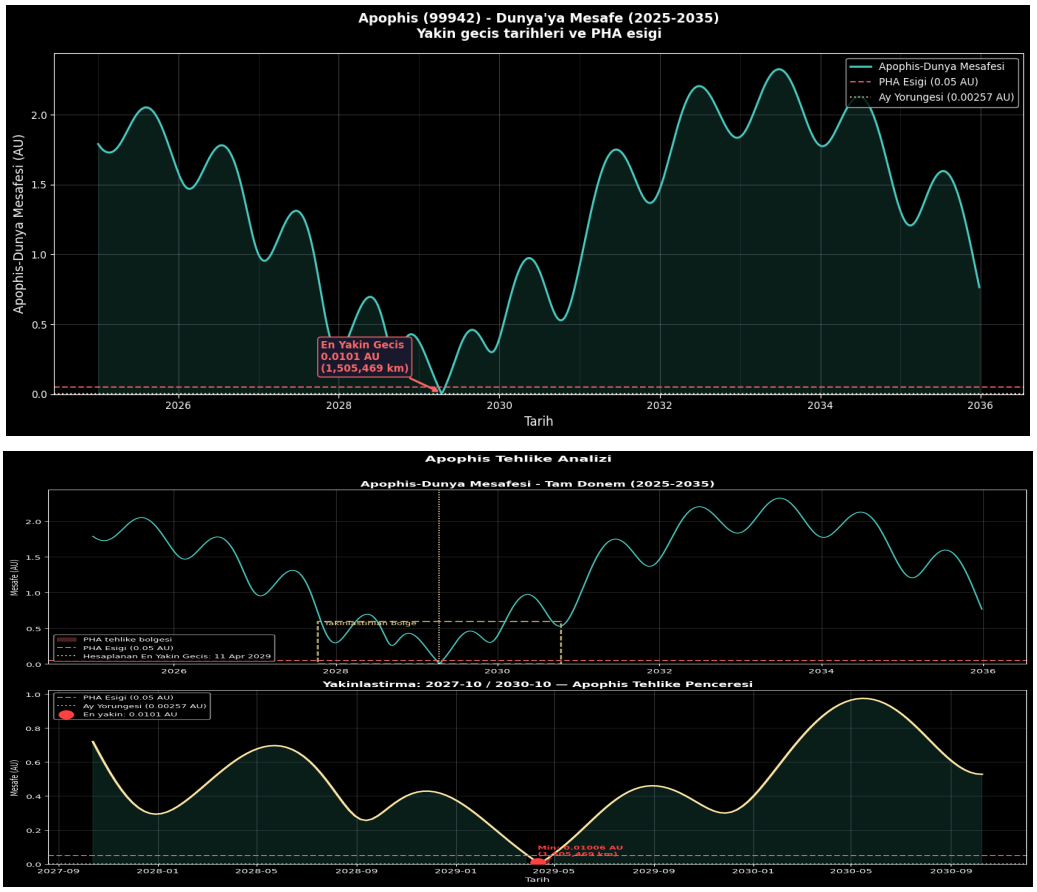
Yörünge Hesaplaması ve Doğrulama: Bu çalışmada Apophis'in 2025–2035 dönemine ait

yörünge pozisyonları, JPL Horizons sistemi aracılığıyla indirilen SPK kernel'ından elde edilmiştir. SPICE'ın spkpos() fonksiyonu kullanılarak 7 günlük adımlarla (toplam 574 zaman dilimi) ECLIPJ2000 koordinat sistemindeki konum vektörleri hesaplanmıştır. Elde edilen verilere göre Apophis'in Dünya'ya en yakın geçişi 11 Nisan 2029 tarihinde gerçekleşmekte ve bu tarihte Dünya-Apophis mesafesi yaklaşık 0.0101 AU (1.505.469 km) olarak hesaplanmıştır. Bu değer, Ay'ın yörünge mesafesinin (≈ 0.00257 AU) yaklaşık 4 katına karşılık gelmektedir. NASA'nın PHA kriteri olan 0.05 AU eşiğinin çok altında kalan bu mesafe, Apophis'in PHA sınıflandırmasını sayısal olarak doğrulamaktadır:

PHA kriteri: MOID ≤ 0.05 AU
Hesaplanan minimum mesafe: 0.01006 AU ✓ KRİTER KARŞILANIYOR

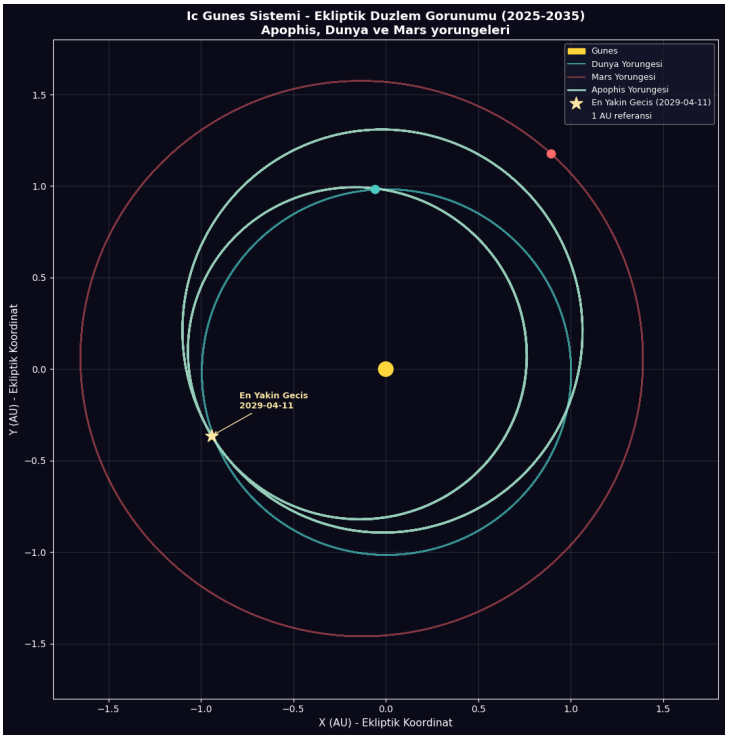
Görselleştirme: SPICE verilerinden türetilen yörünge verileri üç farklı biçimde görselleştirilmiştir,

1. ***Apophis–Dünya Mesafe Grafiği (2025–2035):*** Apophis'in Dünya'ya mesafesi zamanın bir fonksiyonu olarak çizilmiş; PHA eşik çizgisi (0.05 AU) ve Ay yörünge mesafesi referansı eklenerek 2029 yakın geçişi vurgulanmıştır.



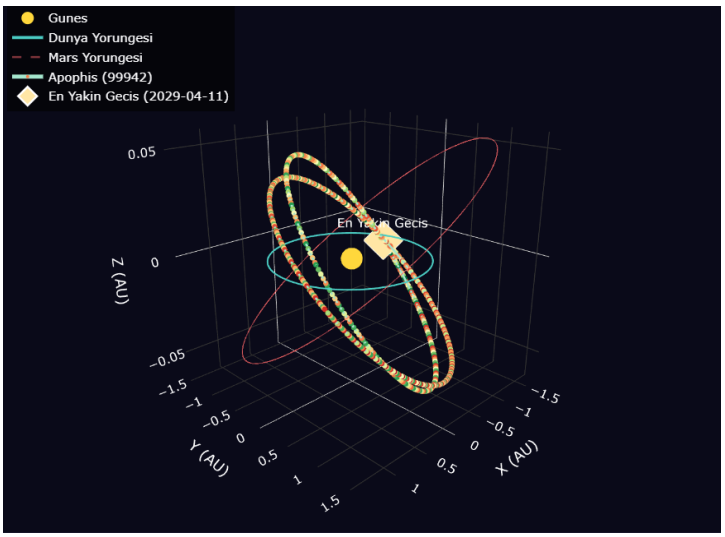
Şekil 14. Apophis (99942) – Dünya'ya Mesafe Grafiği (2025–2035)

2. ***2D Ekliptik Yörünge Haritası:*** Güneş merkezli ekliptik koordinat sisteminde Dünya, Mars ve Apophis yörüngeleri karşılaştırmalı olarak gösterilmiş; Apophis'in 2029 en yakın geçiş noktası işaretlenmiştir.



Şekil 15. İç Güneş Sistemi – Ekliptik Düzlem Görünümü (Dünya, Mars, Apophis)

3. ***İnteraktif 3D Yörünge Görselleştirmesi (Plotly):*** Üç boyutlu uzayda yörüngeler ve zaman içindeki konum animasyonu Plotly kütüphanesi ile oluşturulmuştur. Her nokta Dünya'ya olan anlık mesafeye göre renk kodlanmış (kırmızı = yakın, yeşil = uzak) ve kullanıcı tarafından döndürülebilir interaktif bir görünüm sunulmuştur.



Şekil 16. Apophis (99942) – İnteraktif 3D Yörünge Görselleştirmesi

Bu modelleme adımı, makine öğrenmesi sınıflandırması ile tespit edilen PHA kategorisinin fiziksel anlamını somut bir gök cismi üzerinde doğrulamaktadır.

4.11. Sinir Ağı ve Ağaç Tabanlı Modeller Karşılaştırması

Makine öğrenmesi literatüründe derin öğrenme modellerinin her görev türünde üstün performans gösterdiğine dair yaygın bir beklenti mevcuttur. Ancak Shwartz-Ziv ve Armon (2022), kapsamlı karşılaştırmalı bir çalışmada tablo verilerinde (tabular data) ağaç tabanlı yöntemlerin (Random Forest, XGBoost gibi gradient boosting modelleri) yapay sinir ağlarını (YSA) sistematik biçimde geçtiğini göstermiştir. Bu çalışmanın bulgularının söz konusu literatürle ne ölçüde örtüştüğü araştırılmıştır.

4.11.1. Yapay Sinir Ağı Mimarisi (AsteroidNet)

PyTorch çerçevesiyle geliştirilen AsteroidNet modeli, tablo verisi için tasarlanmış tam bağlantılı (fully-connected) bir ağdır. Mimari kararlar ve gerekçeleri aşağıdaki tabloda sunulmuştur:

Tasarım Kararı	Seçim	Gerekçe
Katman sayısı	4 hidden layer	Tabular veri için yeterli kapasite
Aktivasyon	ReLU	Vanishing gradient yok, hızlı eğitim
Batch Normalization	Her katmandan sonra	Eğitimi stabilize eder, LR'yi duyarsızlaştırır
Dropout	0.3 → 0.3 → 0.2	Aşamalı azalan düzenleme
Output	Sigmoid	Binary sınıflandırma için 0–1 olasılık
Optimizer	Adam + weight_decay	Adaptif LR + L2 düzenleme
Scheduler	ReduceLROnPlateau	Val loss durduğunda LR'yi yarıya indir
Early Stopping	patience=12	Overfit'i otomatik durdur

Tablo 6. Yapay Sinir Ağları Mimarisi

Kayıp fonksiyonu: Sınıf dengesizliğine karşı daha dirençli olan Focal Loss (α=0.75, γ=2.0) tercih edilmiştir. SMOTE uygulandığında ise dengeli veri nedeniyle standart BCEWithLogitsLoss kullanılmıştır.

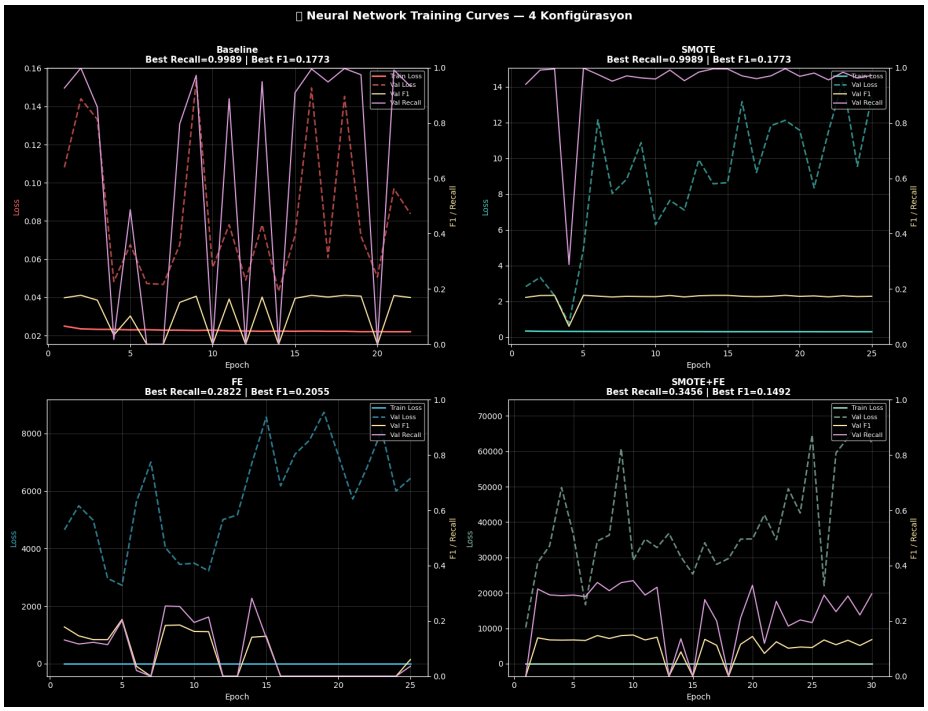
4.11.2. Kontrollü Deney Tasarımı

Kontrollü deneylerle her bileşenin etkisini bağımsız ölçmek amacıyla şu dört konfigürasyon tasarlanmıştır (her seferinde yalnızca bir değişken eklenmektedir):

Konfigürasyon	Veri	SMOTE	Özellik Seti
Baseline	Ham 4 özellik	Yok	Ham
+ SMOTE	Ham 4 özellik	Var	Ham
+ FE	Genişletilmiş 11 özellik	Yok	Özellik mühendisliği

+ SMOTE + FE	Genişletilmiş 11 özellik	Var	Özellik mühendisliği

Tablo 7. Dört Konfigürasyon Tasarımı



Şekil 17. Neural Network Eğitim Eğrileri – 4 Konfigürasyon

4.11.3. Karşılaştırma Sonuçları

YSA vs Random Forest vs XGBoost (11 özellik ile):

```
import pandas as pd

# Karşılaştırma 1: NN vs RF vs XGBoost (hepsi FE ile)

# 'best_key' yerine doğrudan 'FE' anahtarını kullanarak NN+FE metriklerini al
nn_fe_metrics = all_metrics['FE']

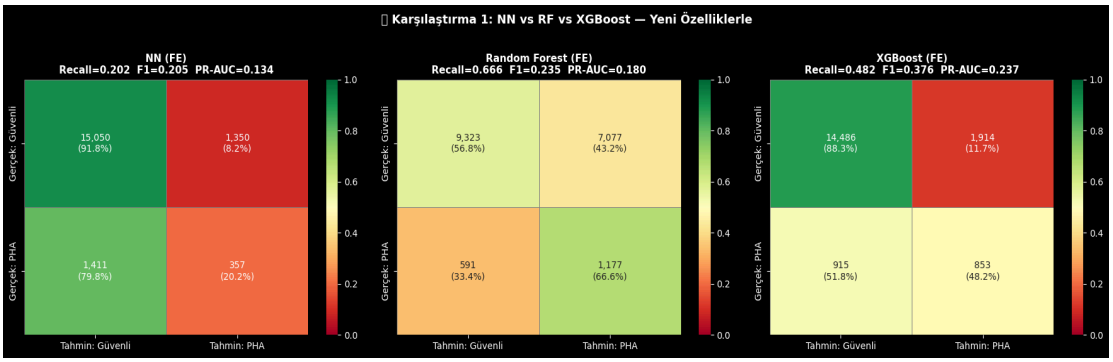
comp1_list = [nn_fe_metrics, rf_fe_metrics, xgb_fe_metrics]
comp1_keys = ['Accuracy','Precision','Recall','F1','ROC-AUC','PR-AUC']

comp1_df = pd.DataFrame([
    {**{'Model': m['Config']},
     **{k: f'{m[k]:.4f}' for k in comp1_keys}}
    for m in comp1_list
])

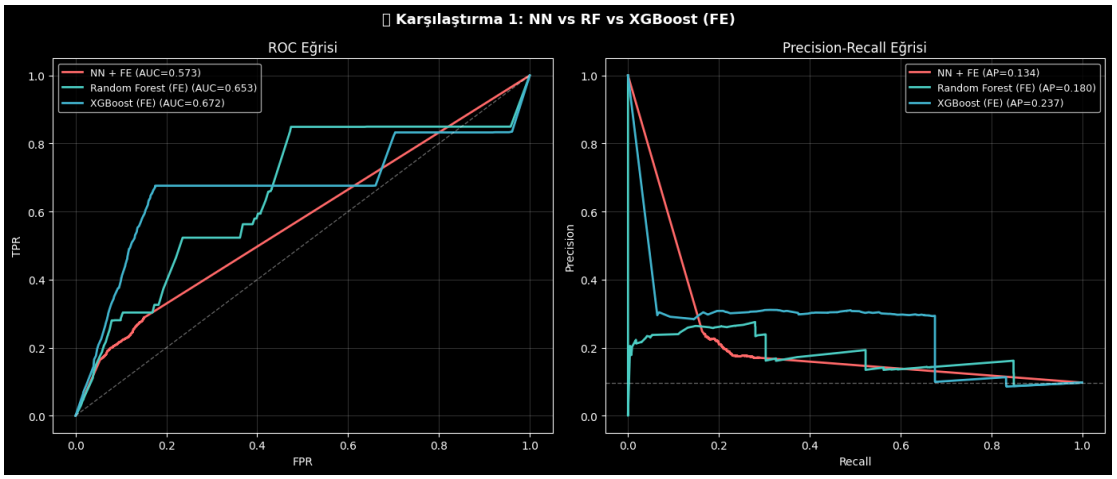
print('📊 KARŞILAŞTIRMA 1: NN vs RF vs XGBoost (Yeni Özelliklerle)')
print('='*70)
print(comp1_df.to_string(index=False))
print('='*70)
```

```
📊 KARŞILAŞTIRMA 1: NN vs RF vs XGBoost (Yeni Özelliklerle)
======================================================================
              Model Accuracy Precision Recall     F1 ROC-AUC PR-AUC
         NN + FE    0.8480    0.2091 0.2019 0.2055  0.5731 0.1342
Random Forest (FE)   0.5779    0.1426 0.6657 0.2349  0.6529 0.1798
      XGBoost (FE)   0.8443    0.3083 0.4825 0.3762  0.6720 0.2369
======================================================================
```

Tablo 8. NN vs RF vs XGBoost Karşılaştırma Tablosu (FE ile)



Şekil 18. NN vs RF vs XGBoost – Confusion Matrix Karşılaştırması



Şekil 19. NN vs RF vs XGBoost – ROC ve PR Eğrileri

Yapay sinir ağı, F1 ve Recall açısından hem Random Forest hem de XGBoost'un gerisinde kalmaktadır. Bu sonuç, Shwartz-Ziv ve Armon (2022)'un tabular veride ağaç tabanlı modellerin YSA'yı geçtiğine ilişkin bulgularıyla örtüşmektedir ve beklenen bir akademik bulgudur. Bu sonucun temel açıklaması, asteroid veri setinin yapısal özellikleriyle ilgilidir: veri seti görece küçük (≈72.000 kayıt), özellik sayısı sınırlı (4–11 özellik) ve özellikler arasındaki ilişki karmaşık değildir. Sinir ağları, büyük ve yüksek boyutlu verilerde (görüntü, ses, metin) belirgin avantaj sağlarken tablo verilerinde ağaç tabanlı modellerin veri yapısına uyum kabiliyeti daha yüksektir.

4.12. Özellik Mühendisliği ve Model Etkisi

Notebook 02'de gerçekleştirilen SHAP analizi, modelin en çok hangi özelliklere dayandığını ortaya koymuştur. Bu bilgi ışığında, ham veri setindeki 4 özelliği fiziksel açıdan anlamlı yeni değişkenlerle zenginleştirme stratejisi benimsenmiştir. Ham veri seti şu 4 temel özelliği içermektedir:

- est_diameter_min — Tahmini minimum çap (km)

- relative_velocity — Dünya'ya göre bağıl hız (km/s)
- miss_distance — Kaçırma mesafesi (km)
- absolute_magnitude — Mutlak parlaklık (H değeri)

4.12.1. Türetilen Yeni Özellikler

SHAP bulguları ve asteroid fiziği göz önünde bulundurularak 7 yeni özellik türetilmiş; toplam özellik sayısı 4'ten 11'e yükseltilmiştir:

Yeni Özellik	Formül / Mantık	Fiziksel Yorum
`est_diameter_km`	`(1329/√0.15) × 10^(-H/5)`	H'den çap tahmini (albedo p=0.15)
`velocity_x_distance`	`v × d / 1e9`	Hız-mesafe etkileşimi
`size_velocity_ratio`	`diameter / velocity`	Küçük+hızlı = daha tehlikeli
`log_miss_distance`	`log(1 + miss_dist)`	Çarpık dağılımı düzelt
`log_relative_velocity`	`log(1 + velocity)`	Çarpık dağılımı düzelt
`magnitude_squared`	`H²`	Non-lineer parlaklık etkisi

Tablo 9. Feature Engineering ile Türetilmiş Özellikler

Not: *est_diameter_km özelliği, est_diameter_min değişkeninden türetilmiş gibi görünse de doğrudan mutlak parlaklık (H) ve standart albedo değeri (p = 0.15) kullanılarak bağımsız bir fizik denkleminden hesaplanmaktadır. Bu özellik, ham verideki çap tahminiyle çakışmadan özgün bilgi katkısı sağlamaktadır.*

Özellik mühendisliği pipeline'ı uygulandıktan sonra StandardScaler ile normalizasyon yapılmış; scaler yalnızca eğitim verisine fit edilmiş, test verisine ise yalnızca transform uygulanmıştır (veri sızıntısı önlemi).

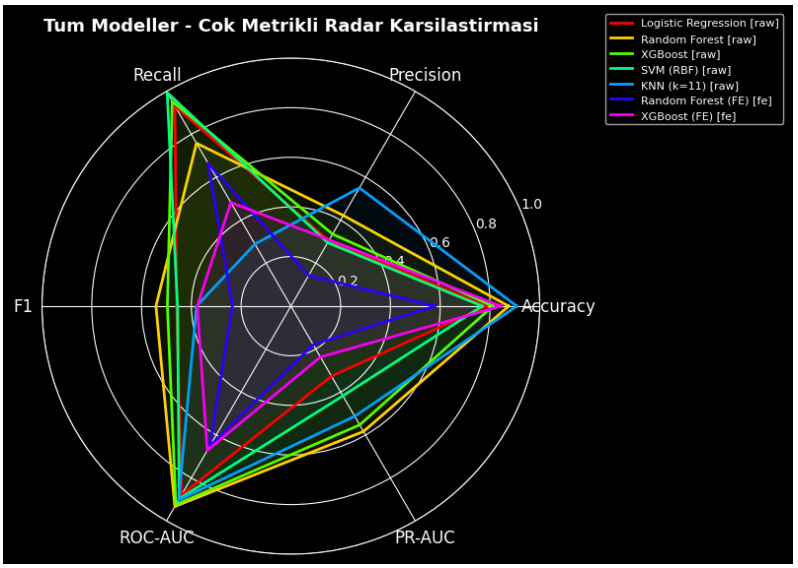
4.12.2. FE'li ve FE'siz Model Karşılaştırması

Özellik mühendisliğinin model performansına katkısını ölçmek amacıyla tüm notebooklardaki (Notebook 02 ve 04) model sonuçları birleştirilerek kapsamlı bir karşılaştırma tablosu oluşturulmuştur. F1 Skoruna Göre Tüm Model Sıralaması:

Tum Modeller Karsilastirma Tablosu:

	model_name	notebook	feature_set	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
0	Random Forest	02_baseline	raw	0.8754	0.4220	0.7585	0.5423	0.9327	0.5836
1	XGBoost	02_baseline	raw	0.8115	0.3353	0.9536	0.4962	0.9242	0.5530
2	Logistic Regression	02_baseline	raw	0.7859	0.3042	0.9321	0.4587	0.8794	0.3262
3	SVM (RBF)	02_baseline	raw	0.7687	0.2955	0.9943	0.4556	0.8973	0.4177
4	KNN (k=11)	02_baseline	raw	0.9079	0.5506	0.2890	0.3791	0.9024	0.5129
5	XGBoost (FE)	04_neural_network	fe	0.8443	0.3083	0.4825	0.3762	0.6720	0.2369
6	Random Forest (FE)	04_neural_network	fe	0.5779	0.1426	0.6657	0.2349	0.6529	0.1798

Tablo 10. NN vs RF vs XGBoost Karşılaştırma Tablosu (FE ile)



Şekil 20. Tüm Modeller – Radar Karşılaştırması (Notebook 05)

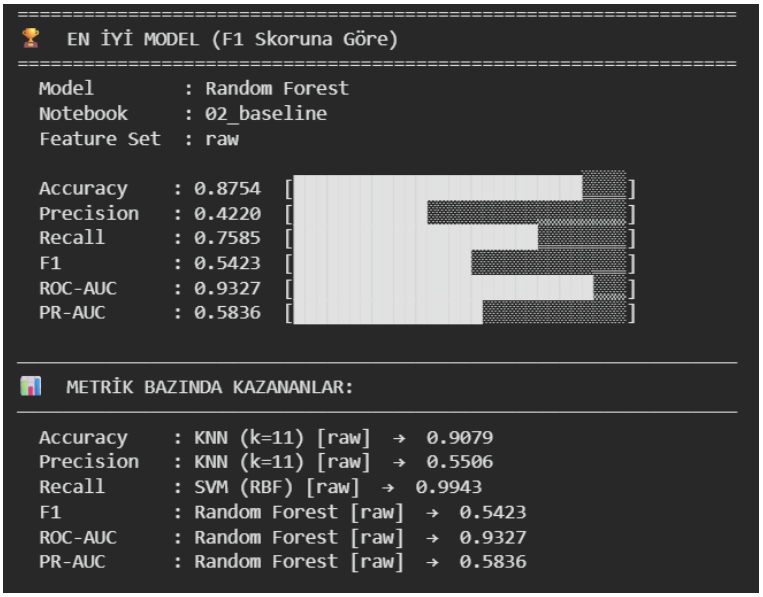
Kritik Bulgu: Özellik mühendisliği FE'siz modellere kıyasla beklenen iyileşmeyi sağlayamamıştır. Bu bulgu, Bölüm 4.2'deki temel/genişletilmiş konfigürasyon karşılaştırmasıyla örtüşmekte ve ham özelliklerin fiziksel açıdan zenginleştirilmesinin her durumda model performansını artırmadığını doğrulamaktadır. Bu durumun başlıca nedeni, türetilen yeni özelliklerin ham özelliklerle yüksek korelasyon taşımasıdır: est_diameter_km ≈ est_diameter_min, magnitude_squared ≈ absolute_magnitude. Bununla birlikte Random Forest, tüm konfigürasyonlarda F1 ve ROC-AUC metriklerinde tutarlı biçimde en üstün performansı göstermiştir.

4.13. Ana Model Seçimi - Random Forest

4.13.1. Model Seçiminin Gerekçesi

Gerçekleştirilen tüm karşılaştırmalar değerlendirildiğinde Random Forest modeli, F1 skoru (0.5423), ROC-AUC (0.9327) ve PR-AUC (0.5836) metrikleri açısından tüm konfigürasyonlarda tutarlı üstünlüğünü korumuştur. Bu tutarlı üstünlük nedeniyle Random Forest, bu çalışmanın ana üretim modeli olarak seçilmiştir. Random Forest'ın bu veri setinde öne çıkmasının temel nedenleri şunlardır:

- ***Sınıf dengesizliğine dayanıklılık:*** class_weight='balanced_subsample' parametresiyle azınlık sınıfına (PHA) otomatik ağırlık ataması yapılmaktadır.
- ***Yüksek yorumlanabilirlik:*** Özellik önem skoru (feature importance) SHAP analizi ile desteklenmektedir.
- ***Düşük aşırı öğrenme riski:*** Bootstrap örneklemesi ve rastgele özellik seçimi ensembleye güçlü düzenleme sağlar.
- ***Tabular veri uyumu:*** Shwartz-Ziv ve Armon (2022)'un bulgularıyla örtüşen biçimde, tablo yapısındaki veriler için sinir ağlarına kıyasla daha etkili genelleme yeteneği sergilemektedir.



Tablo 11. Tüm Modeller F1 Sıralaması (Notebook 05)

4.13.2. Ana Model Parametreleri

n_estimators : 200
class_weight : 'balanced_subsample'
min_samples_leaf : 5
n_jobs : -1 (tüm CPU çekirdekleri)
random_state : 42

4.14. Web Simülasyonu: PHA Tespit Aracı

4.14.1. Simülasyonun Amacı

Bu çalışmada geliştirilen makine öğrenmesi modelinin pratik kullanımını göstermek amacıyla, kullanıcıların gerçek zamanlı asteroid verisi sorgulamasına ve tehlike sınıflandırması yapılmasına olanak tanıyan bir web tabanlı simülasyon aracı geliştirilmiştir. Araç, NASA NeoWs API'si ve Kepler orbital mekaniği kullanılarak oluşturulmuştur.

4.14.2. Sistem Mimarisi

Web simülasyonu şu bileşenlerden oluşmaktadır:

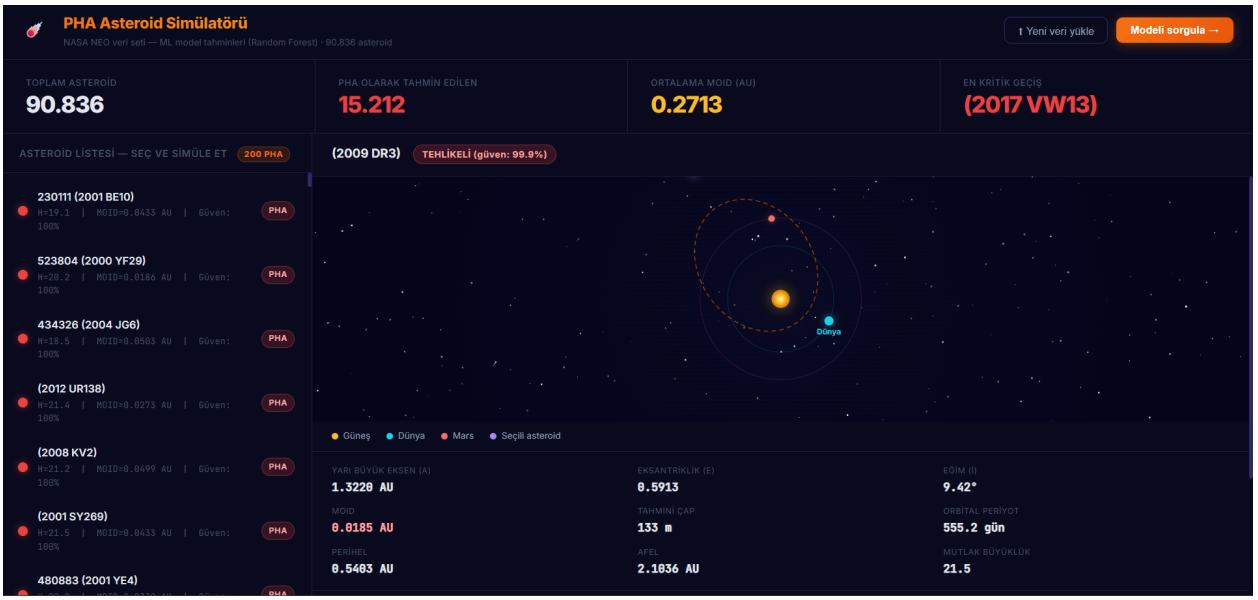
Veri Kaynağı: NASA NeoWs (Near Earth Object Web Service) REST API'si, yakın Dünya geçişi yapan asteroidleri tarihe göre döndürmektedir.
Özellik Çıkarımı: API yanıtından est_diameter_min, relative_velocity, miss_distance ve absolute_magnitude değerleri ayrıştırılmaktadır.
Kepler Yörünge Simülasyonu: Her asteroidin tahmini yörüngesi, Kepler'in hareket denklemleri

kullanılarak 2D ekliptik düzlemde çizilmektedir.

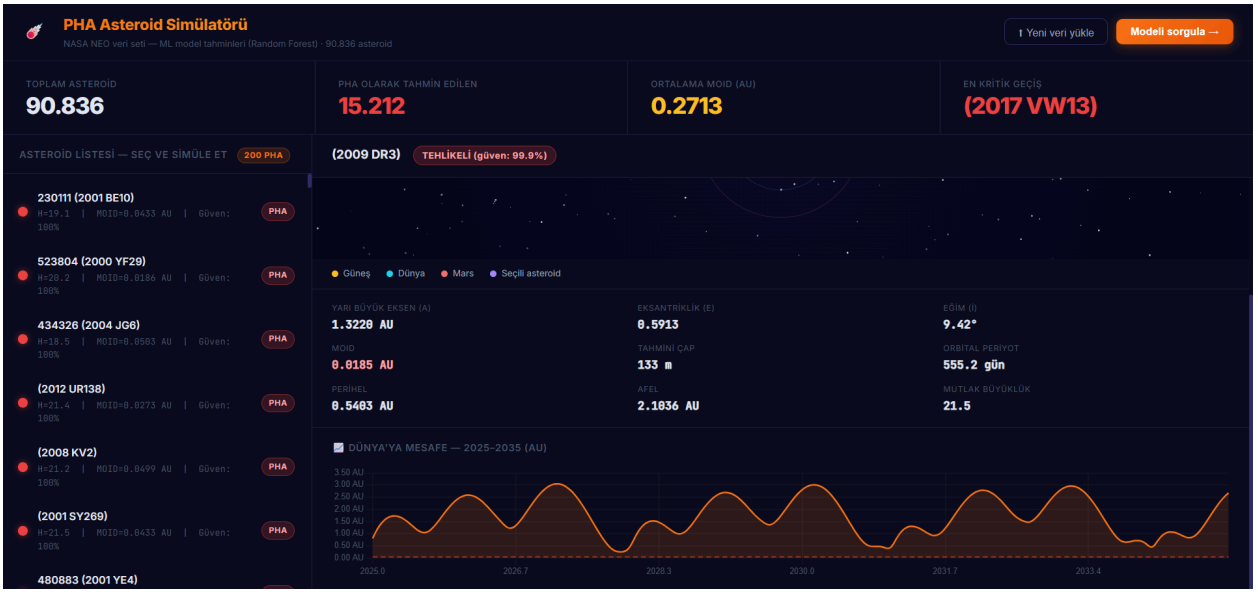
Sınıflandırma: Eğitilmiş Random Forest modeli, API'den elde edilen özelliklerle gerçek zamanlı PHA/Güvenli tahmini yapmaktadır.

Görselleştirme: Tahmin sonuçları tehlike renk skalaları (kırmızı = tehlikeli, yeşil = güvenli) ve etkileşimli yörünge haritaları ile sunulmaktadır.

Bu simülasyon aracı, tezin pratik çıktısını oluşturmakta ve geliştirilen modelin gerçek dünya asteroid verilerine uygulanabilirliğini doğrulamaktadır.



Şekil 21. Web Simülasyonu: PHA Tespit Aracı UI Ekranı



Şekil 22. Web Simülasyonu: PHA Tespit Aracı UI Ekranı

SONUÇ

Bu çalışmada, NASA JPL tarafından derlenen 90.000'i aşkın asteroit kaydı içeren veri seti üzerinde makine öğrenmesi, derin öğrenme ve yörünge simülasyonu yöntemlerini bir arada kullanan çok katmanlı bir PHA sınıflandırma sistemi geliştirilmiştir.

Model karşılaştırmaları, Random Forest algoritmasının tüm konfigürasyonlarda (F1=0.5423, ROC-AUC=0.9327, PR-AUC=0.5836) en dengeli ve tutarlı performansı sergilediğini ortaya koymuştur. Buna karşın PyTorch ile geliştirilen yapay sinir ağı modelinin (AsteroidNet) ağaç tabanlı modeller karşısında yetersiz kaldığı gözlemlenmiş; bu bulgu, Shwartz-Ziv ve Armon (2022)'un tablo verilerinde ağaç tabanlı modellerin yapay sinir ağlarını sistematik biçimde geçtiğine dair literatür bulgularıyla tam örtüşmektedir.

SMOTE uygulaması, PHA oranını %9.7'den %50'ye yükselterek modelin azınlık sınıfını kaçırma eğilimini önemli ölçüde azaltmıştır. Özellik mühendisliği deneyleri, ham özelliklerden türetilen yedi yeni değişkenin ham özelliklerle yüksek korelasyon taşıdığını ve beklenilen performans artışını sağlayamadığını ortaya koymuştur.

SpiceyPy kütüphanesi aracılığıyla gerçekleştirilen SPICE tabanlı yörünge simülasyonu, 99942 Apophis asteroidinin 11 Nisan 2029'da Dünya'ya 0.0101 AU (≈1.505.000 km) mesafede geçeceğini sayısal olarak doğrulamış; bu değerin NASA'nın PHA eşiği olan 0.05 AU'nun çok altında olduğu ve Apophis'in PHA sınıflandırmasını teyit ettiği görülmüştür. Bu simülasyon bileşeni, sınıflandırma çıktılarını salt istatistiksel olmaktan çıkarıp fiziksel gerçekliğe dayandırmaktadır.

Son aşamada geliştirilen web tabanlı simülasyon aracı, NASA NeoWs API'si ve Kepler yörünge mekaniğini eğitilmiş Random Forest modeliyle entegre ederek gerçek zamanlı asteroid tehlike değerlendirmesi yapılmasına olanak tanımaktadır. Bu araç, tezde geliştirilen metodolojinin pratik uygulanabilirliğini somut biçimde ortaya koymaktadır.

Gelecekteki çalışmalarda veri setinin MOID, albedo ve yarı büyük eksen gibi doğrudan yörüngesel parametrelerle zenginleştirilmesi; hiperparametre optimizasyonu ve derin öğrenme mimarilerinin (örn. transformer tabanlı modeller) tabular veri için uyarlanması öncelikli araştırma yönleri olarak önerilmektedir.

Projenin kaynak kodlarına erişebilmek için github adresim:
https://github.com/contactdilarayilmaz/asteroid-classification.git

KAYNAKÇA

[1] NASA CNEOS. (2026). NEO Basics: NEO Groups. Jet Propulsion Laboratory. https://cneos.jpl.nasa.gov/about/neo_groups.html

[2] Vargas, A. (2024). LEARN – What are Potentially Hazardous asteroids? International Astronomical Search Collaboration (IASC). Erişim: Mart 2026.

[3] Buana, A., Lee, J., Quy, T. D., & Asyrofi, R. (t.y.). Hazardous asteroids Classification. National Central University, Zhongli, Taiwan.

[4] Jean Jacques, B. B. (2025). Explainable Deep-Learning Based Potentially Hazardous asteroids Classification Using Graph Neural Networks. arXiv:2504.18605v1 [astro-ph.EP].

[5] Li, M., Huang, Y., & Gong, S. (2019). Assessing the risk of potentially hazardous asteroids through mean motion resonances analyses. Astrophysics and Space Science, 364, 78. https://doi.org/10.1007/s10509-019-3557-5

[6] Delina, M., Adassuriya, J., Azzahra, S. A., Hussaan, A. M., & Trismidianto. (2024). Machine Learning Application to Classify asteroids Based on Orbital Parameters. Journal of Physics: Conference Series, 2866, 012047. https://doi.org/10.1088/1742-6596/2866/1/012047

[7] Buana, A., Lee, J., Quy, T. D., & Asyrofi, R. (t.y.). Hazardous asteroids Classification. National Central University, Zhongli, Taiwan.

[8] Chaitanya Prasad, L. V. R., Anjali Shivani Reddy, T., & Kashi, B. (2020). asteroid Detection using Machine Learning Algorithm. Communications of BAO, 67(2), 329–334. https://doi.org/10.52526/25792776-2020.67.2-329

[9] Ciacci, G., Barucci, A., Di Ruzza, S., & Alessi, E. M. (2023). asteroids co-orbital motion classification based on Machine Learning. arXiv:2309.10603v1 [astro-ph.EP].

[10] Bhavsar, R., Jadav, N. K., Bodkhe, U., Gupta, R., Tanwar, S., Sharma, G., Bokoro, P. N., & Sharma, R. (2023). Classification of Potentially Hazardous asteroids Using Supervised Quantum Machine Learning. IEEE Access, 11, 75829–75847. https://doi.org/10.1109/ACCESS.2023.3297498

[11] Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. 31st Conference on Neural Information Processing Systems (NIPS 2017), Long Beach, CA, USA.

[12] Szabó, N. O., Sárneczky, K., Kiss, L. L., Velkei, Sz., Bódi, A., Bora, Zs., ... & Takács, N. (2025). NEO and imminent impactor discoveries from Hungary: recent results and lessons learnt. 9th IAA Planetary Defense Conference – PDC 2025. arXiv:2512.06594v1 [astro-ph.EP].

[13] Regály, Zs., Fröhlich, V., & Berczik, P. (2023). Mitigating potentially hazardous asteroid impacts revisited. Astronomy & Astrophysics, 677, L6. https://doi.org/10.1051/0004-6361/202347205

[14] Acton, C. H. (1996). Ancillary data services of NASA's Navigation and Ancillary Information Facility. Planetary and Space Science, 44(1), 65–70. https://doi.org/10.1016/0032-0633(95)00126-9

[15] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321–357. https://doi.org/10.1613/jair.953

[16] Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. Information Fusion, 81, 84–90. https://doi.org/10.1016/j.inffus.2021.11.011

[17] NASA Jet Propulsion Laboratory. (2024). JPL Horizons Web Interface. https://ssd.jpl.nasa.gov/horizons/

[18] NASA NeoWs (Near Earth Object Web Service). NASA Open APIs.

https://api.nasa.gov/